

TP 3. Búsqueda de secuencias por similitud

Objetivos

- Familiarizarse con el uso de programas de búsqueda de secuencias en bases de datos.
- Familiarizarse con el uso de parámetros estadísticos en relación a la búsqueda en bases de datos.
- Familiarizarse con el uso de BLAST por línea de comandos usando Google Colab.

Introducción a Bases de Datos de Proteínas

La mayor base de datos de Uniprot es UniProtKB (UniProt KnowledgeBase) que está dividida en dos secciones: TrEMBL y Swiss-Prot.

- TrEMBL es una recolección de proteínas anotadas automáticamente que en su mayoría, aunque no de manera exclusiva, fueron obtenidas a partir de la traducción de secuencias nucleotídicas codificantes (CoDing Sequences, CDS) disponibles en GenBank.
- Swiss-Prot es una base de datos de proteínas que fueron revisadas y anotadas manualmente por un curador/a experto/a. Por lo tanto, Swiss-Prot contiene la información de más alta calidad para secuencias de proteínas.

TrEMBL brinda los datos crudos para que los curadores de Swiss-Prot los revisen. Por lo tanto, TrEMBL tiene más entradas que Swiss-Prot, pero carece de la anotación manual de un experto. En este TP trabajaremos con **Swiss-Prot**.

Parte 1: Introducción a BLAST

El problema de la alineación de a pares

La comparación de secuencias biológicas es fundamental en bioinformática. Métodos como **Smith-Waterman** ofrecen una alineación óptima, pero su costo computacional es prohibitivo. Para dos secuencias de longitudes n y m , Smith-Waterman requiere $O(nm)$ operaciones. Por ejemplo, alinear un ARN de 1000 nucleótidos contra un cromosoma de 100 megabases implicaría **cien mil millones** de cálculos intermedios.

Heurísticas: sacrificar exactitud por velocidad

BLAST (Basic Local Alignment Search Tool) y otros alineadores locales populares utilizan **heurísticas** para reducir drásticamente el espacio de búsqueda. La idea central es identificar rápidamente "semillas" o "**seeds**" —regiones cortas de coincidencia exacta o casi exacta— entre la secuencia **consulta (query)** y la **base de datos (database)**. Solo estas regiones prometedoras se extienden y evalúan con algoritmos más costosos.

En la práctica, BLAST encuentra alineamientos muy buenos de manera rápida pero matemáticamente no garantiza que sea el mejor. Si necesitas el alineamiento perfecto y exacto, hay que usar algoritmos como Smith-Waterman

K-tuplas o k-mers: las palabras de la secuencia

El primer paso de BLAST es dividir la secuencia consulta en todas sus **subcadenas de longitud fija k** . Estas subcadenas se conocen como **k-tuplas**, **k-mers** o **palabras (words)**.

La tabla hash: indexando la consulta

Para poder verificar rápidamente si un k-mer de la base de datos está presente en la consulta, BLAST construye una **tabla hash** (hash table) a partir de los k-mers de la consulta.

Función hash y buckets

Idealmente, se podría usar el k-mer como clave directa en un arreglo. Sin embargo, para proteínas (20 aminoácidos) y $k=10$, existen $20^{10} \approx 10^{13}$ k-mers posibles, lo que requeriría **10 terabytes** de RAM solo para almacenar las posiciones.

Para solucionarlo, se usa una **función hash** que transforma cada k-mer en un número entero más pequeño, que sirve como índice en un arreglo de buckets o slots.

Almacenamiento de posiciones

Cada entrada de la tabla hash (cubeta) almacena una lista de las **posiciones** dentro de la secuencia consulta donde aparece ese k-mer (o sus vecinos).

Vecinos (neighborhood): permitiendo coincidencias inexactas

BLAST no solo busca coincidencias exactas de k-mers. Introduce un **parámetro τ (threshold o umbral)**. Para cada k-mer de la consulta, se calculan todos los **"k-mers vecinos"** cuya puntuación de alineación global contra el k-mer original sea al menos τ . Las posiciones de estos vecinos también se almacenan en la tabla hash.

Esto permite detectar semillas incluso con **sustituciones de aminoácidos o nucleótidos**, mejorando la sensibilidad a costa de un mayor tiempo de búsqueda.

Búsqueda en la base de datos (scanner)

Una vez construida la tabla hash de la consulta (con k-mers y vecinos), BLAST **escanea** secuencialmente cada secuencia de la base de datos. En cada posición, se extrae el k-mer de la base de datos, se aplica la misma función hash, y se **busca en la tabla hash**.

- Si el k-mer de la base de datos **no está** en la tabla, se descarta.
- Si **está** en la tabla (en una cubeta), se obtienen las posiciones en la consulta donde aparece. Esto constituye una **"semilla" (seed) o "hit"**.

Extensión y alineación final (seed-and-extend)

Este es el enfoque **"seed-and-extend"** común a todos los algoritmos basados en tablas hash.

1. **Semillas (seeds)**: Se identifican todos los pares de posiciones (una en la consulta, una en la base de datos) que comparten un k-mer (o vecino).
2. **Extensión**: Alrededor de cada semilla, se intenta **extender** la alineación hacia la izquierda y hacia la derecha, permitiendo gaps (inserciones/eliminaciones).
3. **Puntuación**: La extensión se evalúa usando una **matriz de sustitución** (como BLOSUM para proteínas) y se calcula una puntuación de alineación.
4. **Resultado**: Se seleccionan y reportan las extensiones con las puntuaciones más altas.

Resumen del flujo de BLAST

1. **Entrada**: Secuencia consulta y base de datos.
2. **Indexado**: Se divide la consulta en k-mers. Se construye una tabla hash con los k-mers y sus vecinos (según umbral τ), almacenando las posiciones de cada uno.
3. **Scaneo**: Se recorren las secuencias de la base de datos. Para cada k-mer, se consulta la tabla hash.
4. **Detección de semillas**: Cada coincidencia (exacta o por vecino) genera una semilla (par de posiciones).
5. **Extensión**: Cada semilla se extiende en ambas direcciones para formar una alineación local.
6. **Salida**: Se reportan las alineaciones con las mejores puntuaciones (estadísticamente significativas).

Ejercicio 1

Vamos a replicar manualmente una búsqueda de BLAST. En este ejercicio, vamos a construir un diccionario a partir de la siguiente secuencia:

matematica

Y luego vamos a realizar búsquedas contra el diccionario generado

Extracción de todas las k-tuplas

El primer paso es obtener las k-tuplas que hay en la frase. Para hacerlo, recorreremos la cadena desde la posición 0 hasta $\text{longitud} - k$. Para este ejercicio, las k-tuplas tienen una longitud de 3 ($k=3$)

Posición (i)	k-tupla
0	mat
1	ate
2	tem

Paso 1:

Ahora completa vos las siguientes k-tuplas:

Posición (i)	k-tupla
3	_____
4	_____
5	_____
6	_____
7	_____

Construcción del diccionario hash

Un **diccionario** (tabla hash) tendrá como **clave** cada k-tupla y como **valor** una **lista de posiciones** donde aparece esa k-tupla. Si se repite, su lista debe contener **todas** las posiciones donde aparece.

Clave	Lista de posiciones
mat	[0]
ate	[1]
tem	[2]
ema	[3]

La siguiente Clave es `mat` , así que actualizo ese elemento en la lista de posiciones

Clave	Lista de posiciones
mat	[0, 4]
ate	[1]
tem	[2]
ema	[3]

Paso 2:

Ahora agregá el resto de las claves del diccionario:

Clave (tripleto)	Lista de posiciones
mat	[0]
ate	[1]
tem	[2]
ema	[3]

Búsqueda de consultas (queries) en el diccionario

Usaremos el diccionario para responder rápidamente si una palabra query existe y en qué posiciones.

Hagamos juntos el primer ejemplo con la query **"mat"** :

1. Buscamos la clave `"mat"` en el diccionario.
2. Encontramos que **sí existe** y su valor es `[0, 4]` .

 Paso 3:

Ahora hace lo mismo con las siguientes queries:

Query (tripleto a buscar)	¿Existe en el diccionario? (Sí / No)	Si existe, ¿en qué posición(es)?
ate		
ema		
ati		

Parte 2: Exploración BLAST web

Secciones principales de la interfaz
Encabezado común (Header)

Todas las páginas de BLAST comparten el mismo encabezado con cuatro pestañas principales:

Pestaña	Función
Home	Enlace a la página principal de BLAST
Recent Results	Acceso a los resultados de búsquedas anteriores realizadas en la sesión actual del navegador
Saved Strategies	Estrategias de búsqueda guardadas previamente (requiere cuenta My NCBI)
Help	Documentación completa y ayuda sobre el uso de BLAST

Sección "Web BLAST" (o "Basic BLAST")
Contiene los enlaces a los **cinco programas BLAST más comunes**:

Programa	Secuencia consulta (Query)	Base de datos (Database)	Uso principal
blastn	Nucleótidos	Nucleótidos	Comparar ADN/ARN contra ADN/ARN
blastp	Proteínas	Proteínas	Comparar proteínas contra proteínas
blastx	Nucleótidos (traducido)	Proteínas	Traducir ADN a proteína y buscar en BD de proteínas
tblastn	Proteínas	Nucleótidos (traducido)	Buscar proteína contra ADN traducido en 6 marcos
tblastx	Nucleótidos (traducido)	Nucleótidos (traducido)	Traducir ambos y comparar a nivel proteico

Sección "Specialized searches" (Búsquedas especializadas)

Contiene herramientas adicionales como:

- **CD-search**: Identificación de dominios conservados
- **bl2seq**: Alineamiento de dos secuencias (BLAST 2 Sequences)
- **MegaBLAST**: Búsqueda rápida para secuencias muy similares
- **Discontiguous MegaBLAST**: Para secuencias divergentes

Formulario de búsqueda

Al seleccionar un programa (ej. blastn), se despliega el formulario con varias secciones:

a) **Query Input** (Ingreso de la consulta)

- **Área de texto "Search"**: se pega la secuencia en formato FASTA, secuencia "cruda" o incluso un identificador NCBI
- **Formato FASTA**: comienza con > seguido de una descripción, luego la secuencia
- **Subrange**: permite seleccionar solo un fragmento de la secuencia consulta
- **Carga de archivo**: se puede subir un archivo con una o varias secuencias

b) **Database Selection** (Selección de base de datos)

- **nr**: base de datos no redundante (la más usada)

- **RefSeq Select:** transcritos seleccionados de ratón, rata y humano
- **Genomes:** genomas completos de organismos modelo
- **Organism limit:** restringir por grupo taxonómico
- **Sequence type exclusion:** excluir tipos de registros no deseados

c) **Program Selection** (Selección del programa)

- Para blastn, se puede elegir entre:
- **Megablast** (secuencias muy similares, word size 28)
- **Discontiguous megablast** (secuencias divergentes)
- **blastn** (secuencias algo similares, word size 11)

d) **Algorithm Parameters** (Parámetros del algoritmo)

Parámetro	Explicación	Efecto
Word size	Longitud de la semilla inicial	Mayor → más rápido, menos sensible; Menor → más lento, más sensible
Expect (E-value)	Umbral de significancia estadística	Default: 0.05. Menor → más estricto
Max target sequences	Número máximo de resultados mostrados	Default: 100. Aumentar para ver más resultados
Gap open penalty	Penalización por abrir un hueco	Afecta la cantidad y tamaño de gaps
Gap extend penalty	Penalización por extender un hueco	Similar al anterior
Filtering / Masking	Filtrado de regiones de baja complejidad	Se activa/desactiva en Algorithm Parameters

Resultados de la búsqueda

Al finalizar la búsqueda, los resultados se organizan en varias secciones:

1. **Descriptions:** Lista de secuencias con similitud, ordenadas por E-value
2. **Graphic Summary:** Representación gráfica de los alineamientos
3. **Alignments:** Alineamientos detallados entre query y cada hit
4. **Taxonomy:** Distribución taxonómica de los resultados

Ejercicio 2

Recibieron en el laboratorio una secuencia "incógnita" y deben identificarla usando BLAST.

```
wget "https://raw.githubusercontent.com/mercedesgarnham/Tutoriales/refs/heads/main/TP3/data/secuencia_incognita.fasta"
```

 Pasos a seguir:

1. Ingresen a <https://blast.ncbi.nlm.nih.gov/Blast.cgi>
2. Ingresen a "Nucleotide BLAST"
3. En la sección "Enter accession number(s), gi(s), or FASTA sequence(s)" ingrsá la secuencia incógnita descargada
4. Navegar hasta la sección inferior de la pantalla y apretar el botón "BLAST" para realizar la búsqueda. Ejecute la búsqueda sin cambiar ningún parámetro.

¿Qué estamos viendo?

Secciones principales de los resultados de BLAST

A continuación se explican las cuatro pestañas principales que aparecen en la parte superior de la página de resultados:

Pestaña	¿Qué contiene?	¿Para qué sirve?
Descriptions	Una tabla resumen con todas las secuencias que tienen similitud con tu consulta (query).	Es la vista rápida para identificar los mejores "hits". Te dice el organismo, el puntaje, el E-value y el porcentaje de identidad.

Pestaña	¿Qué contiene?	¿Para qué sirve?
Graphic Summary	Un gráfico de barras que muestra la posición de los alineamientos a lo largo de tu secuencia consulta.	Permite ver de un vistazo si la cobertura es completa o parcial, y si hay múltiples alineamientos en diferentes regiones.
Alignments	Los alineamientos detallados entre tu secuencia y cada una de las secuencias de la base de datos.	Muestra par a par las coincidencias, sustituciones, inserciones y deleciones (gaps). Es donde se puede comprobar la calidad del alineamiento.
Taxonomy	Un resumen de la distribución taxonómica de los resultados (dominio, filo, clase, etc.).	Ayuda a saber si los hits pertenecen a grupos relacionados o si hay contaminación con organismos de otros reinos.

Además, en la parte superior derecha suele haber enlaces a:

- **Reports:** para cambiar el formato de visualización.
- **Lineage:** para ver la jerarquía taxonómica.
- **Organism:** para filtrar por organismo.
- **Taxonomy:** para acceder al árbol taxonómico interactivo.

Análisis de la tabla "Descriptions"

La tabla que has obtenido para la secuencia de la β -globina tiene las siguientes columnas:

Columna	Significado	Ejemplo de tu captura
Description	Nombre de la secuencia y organismo.	<i>Homo sapiens voucher Yoruba_9_0 hemoglobin subunit beta (HBB) gene complete cds</i>
Scientific Name	Nombre científico del organismo.	<i>Homo sapiens</i>
Max Score	Puntuación máxima del mejor alineamiento (contempla coincidencias y penalizaciones).	2852 (muy alto)
Total Score	Suma de puntuaciones si hay varios fragmentos alineados (suele coincidir con Max Score si solo hay un alineamiento).	2852
Query Coverage	Porcentaje de tu secuencia consulta que está cubierta por el alineamiento.	100% (toda la secuencia se alinea)
E-value	Valor esperado: probabilidad de que este alineamiento se dé por azar en una base de datos del mismo tamaño. Cuanto más pequeño, mejor.	0.0 (prácticamente cero)
Per. Ident	Porcentaje de identidad (bases exactamente iguales) en el alineamiento.	99.74% (casi perfecta)
Acc. Len	Longitud total del registro en la base de datos (en pb).	1824
Accession	Identificador único de la secuencia en el NCBI.	<i>MK476483_1</i>

 Preguntas para responder

1. **¿Qué gen has identificado con BLAST?** Nombra el gen completo y el organismo al que pertenece según el mejor hit (primer resultado).
2. **¿Por qué el primer resultado tiene un E-value = 0.0 y un porcentaje de identidad del 99.74%?** Explica con tus palabras qué significa cada uno de estos valores.
3. **¿Qué significa que el "Query Coverage" sea del 100% en todos los primeros hits?** ¿Qué implicación tiene esto sobre la calidad de tu secuencia original?
4. **Observá los cinco primeros resultados. Todos tienen exactamente el mismo Max Score (2852) y Per. Ident (99.74%).** ¿Por qué hay múltiples entradas con los mismos valores si el organismo es el mismo (*Homo sapiens*)?

Ejercicio 3

Realizaron un aislamiento bacteriano y obtuvieron la siguiente secuencia. El objetivo es identificar a que organismo pertenece.

```
wget "https://raw.githubusercontent.com/mercedesgarnham/Tutoriales/refs/heads/main/TP3/data/proteina_incognita.fasta"
```

Pasos a seguir:

1. Ingresen a <https://blast.ncbi.nlm.nih.gov/Blast.cgi>
2. Ingresen a "Protein BLAST"
3. En la sección "Enter accession number(s), gi(s), or FASTA sequence(s)" ingresá la secuencia de la proteína incógnita indicada al comienzo del Ejercicio 3
4. Seleccionen la base de datos "UniProt/Swiss-Prot(swissprot)"
5. Navegar hasta la sección inferior de la pantalla y apretar el botón "BLAST" para realizar la búsqueda.

Graphic Summary

El **Graphic Summary** es una representación visual de los alineamientos entre tu secuencia consulta (query) y las secuencias de la base de datos que han mostrado similitud. Esta vista te permite comprender rápidamente:

- **Cobertura:** qué parte de tu secuencia está alineada.
- **Calidad del alineamiento:** mediante colores que indican el puntaje (score).
- **Distribución de los hits:** si hay múltiples alineamientos en diferentes regiones.
- **Dominios conservados:** si tu proteína contiene regiones funcionales conocidas.

Elementos del Graphic Summary

En la parte superior del gráfico aparece una leyenda con rangos de puntuación:

Rango de Score	Significado
< 40	Alineamiento muy débil
40 - 50	Alineamiento moderadamente bajo
50 - 80	Alineamiento aceptable
80 - 200	Alineamiento bueno
≥ 200	Alineamiento excelente

Interpretación:

Cuanto más azul sea el puntaje, mayor será la coincidencia entre tu secuencia y la de la base de datos.

Alignments

La pestaña **Alignments** muestra el alineamiento detallado **par a par** entre tu secuencia consulta (query) y cada una de las secuencias de la base de datos que han mostrado similitud. Esta sección te permite:

- **Ver exactamente** qué aminoácidos o nucleótidos coinciden.
- **Identificar sustituciones, inserciones y deleciones** (gaps).
- **Evaluar la calidad del alineamiento** a nivel de residuo individual.
- **Acceder a información complementaria** como estructuras 3D o dominios.

En la parte superior de cada alineamiento aparece un recuadro con información clave sobre la secuencia de la base de datos que se está mostrando:

Elemento	Ejemplo en tu captura	Significado
Nombre de la proteína	RecName: Full=Beta-galactosidase; Short=Beta-gal; AltName: Full=Lactase	Nombre completo y sinónimos de la proteína.
Organismo	[Escherichia coli HS]	Especie de la que proviene la secuencia.
Sequence ID	A7WZ1.1	Identificador único en la base de datos del NCBI.

Elemento	Ejemplo en tu captura	Significado
Length	1024	Longitud total de la proteína (en aminoácidos).
Number of Matches	1	Número de fragmentos alineados (si es 1, el alineamiento es continuo).

Estadísticas del alineamiento

Estadística	Valor en tu captura	Significado
Score	125 bits (313)	Puntuación total del alineamiento. Se mide en bits (valor normalizado) y en unidades crudas. 125 bits es muy alto (normalmente > 50 bits es significativo).
Expect (E-value)	2e-34	Valor esperado. La probabilidad de que este alineamiento se dé por azar en una base de datos de este tamaño. 2×10^{-34} es extremadamente bajo, lo que indica que la coincidencia es altamente significativa y no es casual.
Method	Compositional matrix adjust.	BLAST ha ajustado la matriz de sustitución (BLOSUM62) en función de la composición de aminoácidos de tu secuencia para mejorar la sensibilidad.
Identities	60/60 (100%)	60 de 60 aminoácidos coinciden exactamente. 100% de identidad significa que tu fragmento es idéntico a esa región de la proteína de la base de datos.
Positives	60/60 (100%)	60 de 60 aminoácidos son similares (incluye sustituciones conservativas). Al ser 100%, indica que no hay ningún cambio, ni siquiera conservativo.
Gaps	0/60 (0%)	No hay inserciones ni deleciones en el alineamiento. Es un alineamiento perfecto, sin huecos.

El alineamiento visual (alineamiento par a par)

El bloque central muestra la comparación directa entre tu secuencia (Query) y la secuencia de la base de datos (Sbjct).

Taxonomy

La pestaña **Taxonomy** organiza los resultados de BLAST desde una perspectiva **filogenética y taxonómica**. Te presenta un **árbol jerárquico** que agrupa los hits según su clasificación biológica: desde el dominio más amplio (ej. Bacteria) hasta la especie más específica (ej. *Escherichia coli*).

Esta vista es útil para:

- **Identificar rápidamente** a qué grupo taxonómico pertenece tu secuencia.
- **Detectar posibles contaminaciones** (ej. si tu secuencia de bacteria aparece mezclada con hits de hongos o mamíferos).
- **Evaluar la diversidad** de organismos que comparten similitud con tu secuencia.
- **Confirmar la identidad** de tu secuencia viendo que todos los hits relevantes se agrupan en el mismo taxón.

 Preguntas para responder

1. ¿Cuál es el nombre completo de la proteína que aparece en el mejor hit (primer resultado)?
2. ¿A qué organismo pertenece esa proteína?
3. ¿Cuál es el número de acceso (Accession) del mejor hit?
4. Visualizando la pestaña Graphic Summary, **Según la escala de colores de tu captura (rojo = ≥ 200 , verde = 80-200, etc.), ¿qué colores predominan en las barras de los hits?** ¿Qué te dice eso sobre la calidad de los alineamientos?
5. Visualizando la pestaña "Alignments", **En el primer alineamiento detallado, ¿qué porcentaje de identidad y positividad (Positives) muestra el mejor hit?** ¿Hay algún gap (hueco)?
6. Visualizando la pestaña "Taxonomy", **Escribe la jerarquía taxonómica completa** desde el nivel más general (Bacteria) hasta el más específico (cepa) que aparece en los resultados.

Parte 3: Uso de BLAST en la línea de comando

BLAST, tal como es distribuido por el **NCBI**, se encuentra disponible mediante el comando `blastall`. Este comando necesita como mínimo tres argumentos para realizar una búsqueda:

- `-i` una secuencia *query* (recordar, *i* = input)
- `-d` una base de datos con secuencias (recordar, *d* = database)
- `-p` el tipo de búsqueda (*p* = programa: *blastp*, *blastn*, *blastx*, etc.)

Estadística de los Alineamientos

¿Qué es un Expect value o **E-value**?

El E-value (E) es un parámetro que describe el número de hits que uno espera encontrar por azar cuando está buscando en una base de datos de un tamaño particular. Este disminuye exponencialmente a medida que el Score (S) del alineamiento aumenta. Esencialmente el E-value describe el ruido de fondo aleatorio que está presente al realizar una búsqueda en una base de datos de secuencias.

Cuanto más pequeño sea el E-value, o más cercano a 0, más significativo resulta ser nuestro hit. Sin embargo, siempre hay que tener en cuenta que los alineamientos cortos tienen E-values relativamente altos, y esto es debido a que el E-value tiene en cuenta el largo de la secuencia *query*. Estos E-values tienen sentido porque las secuencias cortas tienen una probabilidad más alta de estar presentes en una base de datos puramente por azar.

El E-value es un parámetro conveniente para establecer un umbral de significancia a la hora de reportar los resultados de una búsqueda en una base de datos. Uno puede cambiar el E-value umbral al listar los resultados de una búsqueda con BLAST.

Ejercicio 4

Paso 1

Como primer ejemplo podemos usar la secuencia *xlrhodop.pep* para realizar una búsqueda contra **Swiss-Prot**. Como estamos trabajando con una secuencia y una base de datos de proteínas, usamos `blastp` para realizar la búsqueda.

1. Generar la estructura de trabajo vista en el TP1
2. Descargar la base de datos *Swissprot.fasta*

```
wget "https://raw.githubusercontent.com/mercedesgarnham/Tutoriales/refs/heads/main/TP3/data/Swissprot.fasta"
```

3. Descargar el archivo *xlrhodop.pep*

```
wget "https://raw.githubusercontent.com/mercedesgarnham/Tutoriales/refs/heads/main/TP3/data/xlrhodop.pep"
```

4. Y ejecutar la búsqueda usando BLASTp de *xlrhodop.pep* contra la base de datos de SwissProt

```
blastall -p blastp -i xlrhodop.pep -d Swissprot.fasta
```

Paso 2

En este ejemplo, el resultado de la búsqueda es volcado en la consola (**stdout**). Para que el resultado aparezca en un archivo, podemos redireccionar **stdout** (usando `>`, ver TP01-Linux) o usar la opción `-o` (output).

```
blastall -p blastp -i xlrhodop.pep -d Swissprot.fasta -o xlrhodop.blastp
```

Paso 3

Pueden ver el resultado del `blastp`, por ejemplo, revisando las *n* líneas del principio (head) o del final (tail):

```
head -n 10 xlrhodop.blastp
```

O pueden acceder desde la pestaña de Archivos

Preguntas para responder

- **Inspeccionen el archivo y respondan:** ¿Qué indican las últimas líneas de este archivo?
- Si recuerdan cómo se computa el E-value, ¿cuál es la relevancia de reportar el tamaño de la base de datos (*number of letters, number of sequences*)?

Paso 4

Explore las siguientes opciones del programa `blastp` :

- `-G` Costo del gap open (*default: 11*)
- `-E` Costo del gap extend (*default: 1*)
- `-w` Tamaño de la ktupla. (*default: 3*, puede variar entre 2 y 7)

Hay tuplas de valores permitidos para los argumentos `-G` y `-E` , no cualquier combinación de costos es válida.

- **Pruebe con distintas combinaciones de estos parámetros** y preste atención al impacto que esto tiene en los alineamientos reportados.

Preguntas para responder

a. Si observa los primeros 20 hits de su búsqueda, ¿puede detectar alguna diferencia en los alineamientos reportados si cambia los parámetros indicados más arriba?

b. A medida que va descendiendo en la lista de los hits reportados (menor Score, mayor E-value), ¿qué patrones puede observar en los alineamientos que arroja BLAST?

c. Tome como ejemplo dos de los siguientes hits:

- OPSD_CARAU
- OPN4A_DANRE
- OPN4_RUTRU

y complete para cada uno de los alineamientos reportados la siguiente tabla, teniendo en cuenta los diferentes **costos** de *gap open* y *gap extend* propuestos.

	Número total de gaps	Extensión de las regiones con gaps
Gap open: 6 + gap extend: 2		
Gap open: 13 + gap extend: 1		

Paso Opcional

Evaluando el impacto del parámetro longitud de la k-tupla.

Preguntas para responder

Para una misma combinación de costos para *gap open* y *gap extend* (pueden usar los valores default):

- a.** ¿Qué sucede con los valores de ktupla=2 y ktupla=7 ?
- b.** ¿Cuál búsqueda es la que tarda más? ¿Cuál menos?
- c.** ¿Cuántas secuencias devuelven?

Bibliografía

- Tutorial de BLAST en la web del NCBI: [The Statistics of Sequence Similarity Scores](#)