

TP 4. Uso de información contenida en alineamientos múltiples (Parte I): motivos lineales, expresiones regulares, PROSITE

Objetivos

- 1. Comprender qué son los motivos lineales (SLiMs) y su relevancia biológica.
- 2. Aprender la simbología de las expresiones regulares y cómo se utilizan para representar motivos.
- 3. Construir una expresión regular a partir de evidencia experimental.
- 4. Utilizar herramientas web para visualizar motivos (WebLogo) y buscar motivos en bases de datos (PROSITE, ELM).
- 5. Introducir el concepto de enriquecimiento de motivos mediante MEME.

Introducción a los motivos lineales y expresiones regulares

Motivos lineales (SLiMs)

Los motivos lineales (**Short Linear Motifs**) son segmentos de secuencia de entre 3 y 15 aminoácidos que cumplen funciones específicas, como la unión a otras proteínas, la localización subcelular, la fosforilación o la degradación. A diferencia de los dominios globulares, los SLiMs suelen encontrarse en regiones desordenadas de las proteínas y son muy degenerados: toleran sustituciones de aminoácidos en varias posiciones, lo que permite una rápida evolución y regulación.

Expresiones regulares (Regex)

Una expresión regular es una cadena de caracteres que describe un patrón de búsqueda. En bioinformática, se utilizan para representar motivos de secuencia de forma compacta. La sintaxis más común es la empleada por **PROSITE** y muchas herramientas de búsqueda de motivos.

Símbolo	Significado
.	Cualquier aminoácido (o nucleótido) es permitido.
[XY]	Solo los aminoácidos X e Y son permitidos.
[^XY]	Los aminoácidos X e Y están prohibidos.
{min,max}	Número mínimo y máximo de veces que se puede repetir una posición (ej. <code>x{2,3}</code>).
^X	El aminoácido X se encuentra en el extremo N-terminal.
X\$	El aminoácido X se encuentra en el extremo C-terminal.
A B	Se encuentra, o bien el aminoácido A, o bien el B (alternancia).
(AB) (CD)	Se encuentra la secuencia AB o la secuencia CD.

Las expresiones regulares pueden combinarse para describir motivos más complejos. Por ejemplo, el motivo de unión a Rev1 que veremos más adelante se representa como `FF[^P]{0,2}[KR]{1,2}[^P]{0,4}` .

Ejercicio 1: Construcción de expresiones regulares a partir de ejemplos de motivos conocidos

En este ejercicio, vamos a practicar la construcción de expresiones regulares para diferentes motivos lineales descritos en la literatura. Para cada motivo, se proporcionan ejemplos de secuencias que lo cumplen. Tu tarea es deducir la expresión regular que los representa.

Motivo 1: DOC_CYCLIN_RxL_1

Descripción: Motivo de anclaje (docking) reconocido por los complejos Ciclina/CDK de la fase S en hongos y mamíferos. La expresión regular canónica es `[RK].L.{0,1}[FYLIIVMP]`.

Ejemplos de secuencias que cumplen el motivo:

- RMLP
- EKSLTSP
- KSLGI

Paso 1:

Escribe la expresión regular que representa este motivo, basándote en los ejemplos. Utiliza la sintaxis de PROSITE. Luego, verifica con regex101 que tus ejemplos coinciden.

Motivo 2: LIG_ARL_BART_1

Descripción: Motivo presente en el extremo N-terminal de las proteínas ARL2 y ARL3 que asegura la unión dependiente de GTD a BART y BARTL1. La expresión regular es `^..LL[^P]IL[^P][^P][LM]`.

Ejemplos de secuencias que cumplen el motivo:

- MLLLDIIDL
- LALLPIIDM
- LALLGIIDM

Paso 2:

Escribe la expresión regular para este motivo. Presta atención al símbolo `^``, que indica que el motivo debe estar al inicio de la secuencia. Verifica con los ejemplos.

Motivo 3: LIG_PDZ_Class_1

Descripción: Motivo de unión a dominios PDZ de clase 1, clásicamente representado por el patrón `(ST)X(VIL)` en el extremo C-terminal. La expresión regular es `[ST].[ACVILF]$`.

Ejemplos de secuencias que cumplen el motivo:

- SRA-COOH (termina en SRA)
- STA-COOH (termina en STA)

Paso 3:

Escribe la expresión regular para este motivo. Observa el uso de ``$`` para indicar el extremo C-terminal. Verifica con los ejemplos.

Motivo 4: DOC_PP2A_B56_1

Descripción: Sitio de anclaje requerido por la subunidad reguladora B56 de la fosfatasa PP2A para la desfosforilación de proteínas. La expresión regular es $([LMFYWIC]..I.E) | (L..[IVLWIC].E)$.

Ejemplos de secuencias que cumplen el motivo:

- MLPAIA
- MLPAIAE (contiene el motivo MLPAIA)
- MLPAAE (contiene MLPAA)

Paso 4:

Escribe la expresión regular para este motivo. Ten en cuenta que hay dos variantes separadas por `|`. Verifica con los ejemplos.

Motivo 5: Motivo de unión a Rev1

Descripción: Motivo que media la interacción con la polimerasa TLS Rev1. La evidencia experimental indica:

- Dos fenilalaninas consecutivas (FF).
- Entre 0 y 2 aminoácidos que no pueden ser prolina ($[^P]\{0,2\}$).
- Entre 1 y 2 aminoácidos con carga positiva (K o R) ($[KR]\{1,2\}$).
- Entre 0 y 4 aminoácidos que no pueden ser prolina ($[^P]\{0,4\}$).

Ejemplos de secuencias que cumplen el motivo (fragmentos):

FFSKQ
FFSRINK
FFIKKE
FFGKAA
FFSKKQ
FFQKAA
FFDKKR

Paso 5:

Construye la expresión regular para el motivo de unión a Rev1. Escríbela y verifica con los ejemplos dados. La expresión regular canónica en la base de datos ELM es: $FF[^P]\{0,2\}[KR]\{1,2\}[^P]\{0,4\}$. Compara tu resultado con esta.

Pregunta 1:

De todos los motivos vistos, ¿cuál tiene la expresión regular más restrictiva (menos secuencias posibles)? ¿Cuál es la más permisiva? Justifica tu respuesta.

Ejercicio 2: Conteo de secuencias posibles y probabilidad de motivos

En este ejercicio vamos a calcular cuántas secuencias diferentes pueden cumplir un determinado patrón, y también estimaremos la probabilidad de que un motivo aparezca al azar en una proteína, utilizando las frecuencias de aminoácidos en el proteoma humano.

Parte A: Conteo de secuencias posibles

Para cada una de las siguientes expresiones regulares, calcula el número total de secuencias de la longitud indicada que cumplen el patrón. Considera que el alfabeto proteico tiene 20 aminoácidos.

- 1. R.K (3 aminoácidos: R, cualquier aa, K)
- 2. R. .K (4 aminoácidos: R, dos cualquier aa, K)
- 3. R. [RK] (3 aminoácidos: R, cualquier aa, y luego R o K)
- 4. R[^P][RK] (3 aminoácidos: R, cualquier aa excepto P, y luego R o K)

 Paso 6:

Completa la siguiente tabla:

Expresión regular	Número de secuencias posibles
R.K	
R. .K	
R. [RK]	
R[^P][RK]	

 Pregunta 2:

¿Cuál de los cuatro patrones es el más restrictivo? ¿Por qué? ¿Cuál es el más permisivo?

Parte B: Probabilidad de aparición de un motivo al azar

Para estimar si un motivo es estadísticamente significativo, necesitamos calcular la probabilidad de que aparezca por azar en una secuencia. Para ello, utilizamos las frecuencias de aminoácidos en el proteoma humano (o en el conjunto de proteínas de interés).

A continuación se muestra una tabla de frecuencias (obtenidas de UniProt, considerando regiones con puntaje de desorden IUPred ≥ 0.4):

Aminoácido	Frecuencia	Aminoácido	Frecuencia
A (Ala)	0.074253	M (Met)	0.019150
C (Cys)	0.009697	N (Asn)	0.033851
D (Asp)	0.050147	P (Pro)	0.094297
E (Glu)	0.089011	Q (Gln)	0.056396
F (Phe)	0.018359	R (Arg)	0.063802
G (Gly)	0.073955	S (Ser)	0.104119
H (His)	0.025784	T (Thr)	0.059547
I (Ile)	0.026977	V (Val)	0.045399
K (Lys)	0.061170	W (Trp)	0.006850
L (Leu)	0.073093	Y (Tyr)	0.014141

Ejemplo: El motivo $DP[FW]$ (que corresponde a la clase $LIG_AP2alpha_2$ en ELM) tiene dos posibles variantes: DPF y DPW . La probabilidad de que aparezca al azar es:

$$P(DPF) + P(DPW) = F(D) \cdot F(P) \cdot F(F) + F(D) \cdot F(P) \cdot F(W)$$

Usando las frecuencias de la tabla:

- $F(D) = 0.050147$
- $F(P) = 0.094297$
- $F(F) = 0.018359$
- $F(W) = 0.006850$

Entonces:

$$P(DPF) = 0.050147 \cdot 0.094297 \cdot 0.018359 \approx 8.68 \times 10^{-5}$$

$$P(DPW) = 0.050147 \cdot 0.094297 \cdot 0.006850 \approx 3.24 \times 10^{-5}$$

$$P(\text{total}) = 8.68e-5 + 3.24e-5 \approx 1.19 \times 10^{-4}$$

Eso significa que, en promedio, el motivo $DP[FW]$ aparecería una vez cada ~8400 aminoácidos.

Paso 7:

Calcula la probabilidad de aparición al azar de los siguientes motivos, utilizando las frecuencias de la tabla:

- $D.[FW]$ (D, cualquier aa, y luego F o W)
- CP (C seguido de P)
- $R[^P][RK]$ (utiliza las frecuencias de R, de cualquier aa excepto P, y de R o K)

Para el inciso c), recuerda que la probabilidad de $[^P]$ es $1 - F(P) = 1 - 0.094297 = 0.905703$. La probabilidad de $[RK]$ es $F(R) + F(K) = 0.063802 + 0.061170 = 0.124972$.

Pregunta 3:

Ordena los motivos $DP[FW]$, $D.[FW]$, CP y $R[^P][RK]$ de mayor a menor probabilidad de aparición al azar. ¿Cuál de ellos es el más raro y, por lo tanto, potencialmente más informativo?

Ejercicio 3: Reconocimiento de secuencias que cumplen un patrón

Dada la siguiente expresión regular:

$$[RK] \cdot \{0, 1\}[P] \cdot \{2\}[^P]$$

Indica cuáles de las siguientes secuencias **cumplen** el motivo (puede ser más de una):

- A. RPAVL
- B. KAPLRP
- C. RRPAPP
- D. RRP GPA
- E. R PGPA

Paso 8:

Para cada secuencia, escribe si cumple o no, y justifica brevemente tu respuesta (por ejemplo, indicando qué parte del patrón falla o coincide).

Pregunta 4:

¿Cuál es la longitud mínima y máxima de una secuencia que puede cumplir este motivo? (Considerando que `{0,1}` puede ser 0 o 1 aa, y `{2}` son exactamente 2 aa).

Ejercicio 1: Construcción de una expresión regular a partir de evidencia experimental

Vamos a trabajar con el motivo de unión a la proteína **Rev1**, que participa en la reparación del ADN por Translesion Synthesis (TLS). La evidencia experimental (obtenida de estudios estructurales y de mutagénesis) indica que:

- El motivo está mediado por **dos fenilalaninas consecutivas** (FF).
- Estas fenilalaninas son seguidas por una región de **0 a 2 aminoácidos** que no pueden ser prolina (P).
- Luego hay **1 o 2 aminoácidos** con carga positiva (lisina K o arginina R).
- Finalmente, una región de **0 a 4 aminoácidos** que no pueden ser prolina (P).

A continuación se muestran fragmentos de secuencia de proteínas que se unen a Rev1 (la interacción fue verificada experimentalmente):

sp|Q03834|MSH6_YEAST|31-38
SQKKMKQSSLLSFFSKQVPSGTPSKKVQ

sp|Q60596|XRCC1_MOUSE|191-200
DDSANSLKPGALFFSRINKTSSASTSDPAG

sp|Q9H040|SPRTN_HUMAN|418-428
RPRLEDKTVFDNFFIKKEQIKSSGNDPKYST

sp|Q15054|DPOD3_HUMAN|236-245
NKAPGKGNMMSNFFGKAAMNKFVNLDSQ

sp|Q9UNA4|POLI_HUMAN|569-579
SCPLHASRGVLSFFSKQMDDIPINPRDHL

sp|Q9Y253|POLH_HUMAN|481-490
TATKKATTSLESFFQKAERQKVKEASLSS

sp|Q9QUG2|POLK_MOUSE|564-575
LAKPLEMSHKKSFFDKKRSEISNCQDTSRCK

Paso 1: Identificar el motivo común

1. Copia las secuencias anteriores y pégalas en la herramienta **regex101** (<https://regex101.com>) en el recuadro "Test String".
2. En el campo "Regular Expression", escribe una expresión regular que capture el motivo descrito por la evidencia experimental. Recuerda utilizar la sintaxis:
 - F y F para las fenilalaninas.
 - $[^P]\{0,2\}$ para la región sin prolina de 0 a 2 posiciones.
 - $[KR]\{1,2\}$ para una o dos cargas positivas.
 - $[^P]\{0,4\}$ para la región final sin prolina de 0 a 4 posiciones.
3. Verifica que tu expresión regular encuentre todas las secuencias del listado (debería haber al menos una coincidencia por cada fragmento).

Pregunta 1:

Escribe la expresión regular que construiste. ¿Coincide con la que se usa en la base de datos ELM (que es `FF[^P]{0,2}[KR]{1,2}[^P]{0,4}`)? Si no, ajusta la tuya para que sea equivalente.

Paso 2: Evaluar una secuencia adicional

Ahora prueba si la siguiente secuencia (de la levadura *Saccharomyces cerevisiae*) cumple con el motivo:

```
sp|Q04049|POLH_YEAST|625-632
KKQVTSSKNILSFFTRKK
```

Pégala en regex101 (añádela al "Test String") y observa si tu expresión regular la reconoce.

Pregunta 2:

¿La secuencia de levadura contiene el motivo? Si no, ¿por qué crees que podría no unirse a Rev1, a pesar de ser una polimerasa TLS? (Pista: piensa en la especificidad de especie y en la conservación evolutiva).

Ejercicio 2: Búsqueda de motivos con PROSITE y ELM

En este ejercicio utilizaremos **PROSITE** (base de datos de patrones de proteínas) y **ELM** (base de datos de motivos lineales eucariotas) para buscar motivos en una proteína de interés: la proteína **p53 humana** (UniProt ID: P01308, aunque el ID correcto para p53 es P04637, pero usaremos el que aparece en los materiales).

Paso 1: Búsqueda en PROSITE con ScanProsite

1. Ve a la página de **ScanProsite** en ExPASy: <https://prosite.expasy.org/scanprosite/>.
2. En el recuadro de texto, pega la secuencia de p53 humana (puedes obtenerla de UniProt con el ID **P04637**). Asegúrate de que esté en formato FASTA.
3. Ejecuta la búsqueda con los parámetros por defecto (selecciona "Scan for PROSITE patterns").
4. Una vez que termine, examina los resultados. La página te mostrará qué motivos (patrones) de PROSITE se encuentran en tu secuencia, junto con sus posiciones.

Pregunta 5:

¿Cuántos motivos de PROSITE se han encontrado en p53? Nombra al menos dos de ellos y explica su función (por ejemplo, sitio de fosforilación, señal de localización nuclear, etc.).

Pregunta 6:

¿Aparece el motivo de unión a MDM2 (`F[^P]{3}W[^P]{2,3}[VIL]`) en los resultados de PROSITE? Si no, ¿por qué crees que no está catalogado en PROSITE? (Pista: PROSITE se enfoca en motivos bien caracterizados y de longitud fija).

Paso 2: Predicción de motivos lineales con ELM

1. Ve a la página de predicción de ELM: <http://elm.eu.org/>. Haz clic en la pestaña "**Prediction**".
2. Ingresa el UniProt ID de p53 humana: **P04637**. Deja los parámetros por defecto:
 - **Cell Compartment:** Not specified
 - **Motif Probability Cutoff:** 100
 - **Taxonomic context:** (vacío)
3. Ejecuta la predicción.

4. Observa la tabla de resultados. Fíjate en la columna **"Filtering Summary"** para ver cuántas instancias de motivos se encontraron y cuántas fueron retenidas después de aplicar los filtros estructurales y de contexto.

 Pregunta 7:

¿Cuántas instancias de motivos se predicen en p53? ¿Cuántas son retenidas tras los filtros (por ejemplo, filtros de desorden estructural)? ¿Qué motivos anotados como **true positives** (positivos verdaderos) aparecen?

5. Ahora modifica los parámetros:

- **Cell Compartment:** selecciona **"Nucleus"** (ya que p53 es una proteína nuclear).
- **Motif Probability Cutoff:** 0.01 (para hacer la predicción más estricta).
- **Taxonomic context:** escribe **"Homo sapiens"**.

6. Vuelve a ejecutar la predicción.

 Pregunta 8:

Compara los resultados de la predicción con filtros (punto 5) con los obtenidos sin filtros (punto 2). ¿Cuántas instancias se retienen ahora? ¿Qué motivos específicos (por ejemplo, MOD_CK1_1 , DOC_CYCLIN_RXL_1) se encuentran? ¿Tiene sentido biológico que estos motivos aparezcan en p53?

Ejercicio 3: Identificación de motivos sobre-representados con MEME

En este ejercicio utilizaremos **MEME** (*Multiple EM for Motif Elicitation*) para descubrir motivos de secuencia que estén enriquecidos en un conjunto de secuencias, sin necesidad de alinearlas previamente.

Paso 1: Buscar motivos en las secuencias de unión a Rev1

1. Ve a la web de MEME: <https://meme-suite.org/meme/tools/meme>.
2. En "Input the primary sequences", selecciona **"Type in sequences"** y pega las secuencias del Ejercicio 1 (las que contienen el motivo de unión a Rev1) en formato FASTA.
3. Configura los parámetros:
 - **Select the site distribution:** *Zero or One Occurrence Per Sequence (zoops)*
 - **Select the number of motifs:** 10
 - En **Advanced Options:**
 - **Background model:** *0-order model of sequences*
 - **Minimum width:** 4
 - **Maximum width:** 12
 - **Minimum sites:** 2
 - **Maximum sites:** 10
4. Ejecuta la búsqueda (puede tardar unos minutos).
5. Una vez finalizada, examina los resultados. MEME mostrará los motivos encontrados, con sus logos de secuencia y sus E-values.

 Pregunta 9:

¿Recupera MEME el motivo de unión a Rev1 (el que contiene el patrón FF...) como uno de los motivos significativos? Si no, ¿a qué crees que se debe? (Pista: MEME busca motivos sin gaps, pero el motivo de Rev1 tiene regiones variables y puede ser dividido en dos motivos separados).

Paso 2: Repetir la búsqueda con secuencias aleatorizadas

1. En la misma página de MEME, repite la búsqueda pero esta vez marca la opción **"Shuffle the sequences"** (en Advanced Options).
2. Ejecuta de nuevo.

Pregunta 10:

Compara los resultados de la búsqueda con secuencias originales y con las secuencias aleatorizadas. ¿Qué diferencias observas en los motivos encontrados y en su significancia estadística? ¿Qué nos dice esto sobre la especificidad de los motivos identificados?

Cierre y reflexión final

En este TP hemos aprendido a:

- Interpretar y construir expresiones regulares para representar motivos de secuencia.
- Utilizar herramientas como WebLogo para visualizar la conservación en un alineamiento.
- Buscar motivos en bases de datos curadas (PROSITE, ELM) y entender sus limitaciones.
- Emplear MEME para descubrir motivos enriquecidos *de novo*.

Completa la siguiente tabla para resumir lo visto:

Tema	Herramienta(s) utilizada(s)	Tipo de datos	Análisis del resultado
Expresiones regulares	(completar)	(completar)	(completar)
Logos de secuencia	(completar)	(completar)	(completar)
Búsqueda de motivos en bases de datos	(completar)	(completar)	(completar)
Descubrimiento de motivos <i>de novo</i>	(completar)	(completar)	(completar)

Objetivos alcanzados

- Comprender qué son los motivos lineales y su relevancia biológica. (Sí / No)
- Conocer la simbología de expresiones regulares y aplicarla en la búsqueda de motivos. (Sí / No)
- Utilizar herramientas web para visualizar motivos (WebLogo) y buscar en bases de datos (PROSITE, ELM). (Sí / No)
- Introducir el concepto de enriquecimiento de motivos con MEME. (Sí / No)

Bibliografía complementaria

- PROSITE documentation: <https://prosite.expasy.org/>
- ELM resource: <http://elm.eu.org/>
- MEME Suite: <https://meme-suite.org/>
- Crooks GE, Hon G, Chandonia JM, Brenner SE (2004) WebLogo: A sequence logo generator. *Genome Research* 14:1188-1190.
- Dinkel H, Van Roey K, Michael S, et al. (2016) ELM 2016—data update and new functionality of the eukaryotic linear motif resource. *Nucleic Acids Research* 44(D1): D294-D300.