

TP 5. Uso de información contenida en alineamientos múltiples (Parte II): PSI-BLAST, PSSMs, HMMs, Sequence Logos

Objetivos

1. Construir e interpretar **Sequence Logos** a partir de alineamientos de secuencias.
2. Comprender el concepto de **PSSM** (Position-Specific Scoring Matrix) y su utilidad para representar la conservación en un alineamiento múltiple.
3. Familiarizarse con **PSI-BLAST** y su capacidad para detectar homólogos distantes mediante búsquedas iterativas.
4. Comprender y construir un perfil HMM desde un alineamiento múltiple y realizar búsquedas en bases de datos.
5. Utilizar InterPro para la identificación de dominios y familias.

Introducción

De motivos lineales a dominios globulares

En el TP4 trabajamos con motivos lineales (SLiMs): secuencias cortas (3-15 aminoácidos), muy degeneradas, que suelen residir en regiones desordenadas de las proteínas y que pudimos representar mediante expresiones regulares. Sin embargo, la mayoría de las proteínas están organizadas en unidades estructurales y funcionales mucho más grandes llamadas dominios.

Un dominio proteico es una región de la proteína que puede plegarse de manera independiente y que posee una función específica (por ejemplo, unión a ATP, unión a ADN, actividad catalítica). Los dominios tienen características muy diferentes a los motivos lineales:

- Son más largos: típicamente de 50 a 250 aminoácidos.
- Están mucho más conservados evolutivamente.
- Presentan una arquitectura 3D globular estable.
- Aceptan inserciones y deleciones (gaps) en sus regiones variables, que son fundamentales para la evolución de la familia.

Mientras que un motivo lineal se puede buscar con una expresión regular (una cadena de texto), un dominio requiere un modelo mucho más rico que asigne pesos específicos a cada posición (PSSM) y que modele probabilísticamente las inserciones y deleciones (HMM). Por eso, en este TP vamos a utilizar herramientas como PSI-BLAST y HMMER para construir y buscar estos perfiles de dominios, y los representaremos visualmente mediante Sequence Logos.

Ejercicio 1: Generación e interpretación de un Sequence Logo

Sequence Logos

Un **Sequence Logo** es una representación gráfica de una PSSM. En cada posición, la altura total de la columna de letras es proporcional al contenido de información (conservación), y la altura de cada letra refleja su frecuencia en esa posición. Los colores suelen agrupar aminoácidos por propiedades químicas. Los logos permiten visualizar de un vistazo las posiciones conservadas y las variables.

Los logos son una herramienta muy útil para visualizar motivos de unión. En un logo de secuencia se grafica en el *eje* y el **contenido de información** de cada posición del motivo, generalmente expresado en *bits*. A su vez, la frecuencia con la que aparece una letra (nucleótido u aminoácido) en una dada posición se grafica con un tamaño proporcional a dicha magnitud.

Un servidor que nos permite generar fácilmente logos de secuencia es [Seq2Logo](#). Este método nos da la opción de ingresar un alineamiento múltiple (MSA), una lista de péptidos o una matriz peso-específica con la cual realizar el gráfico.

La información puede pegarse directamente en el **cuadro de texto** que provee la web, o subiendo directamente un archivo local utilizando la opción **Switch to file upload** que se encuentra debajo del cuadro.

 seq2logo1

Dentro de las opciones que nos permite cambiar tenemos:

- **Logo type:** Esto refiere a la magnitud que se calculará para cada posición y se graficará en el eje y (Kullback-Leiber, Shannon, etc.).
- **Clustering method:** Agrupa las secuencias que son muy similares para no sesgar el resultado, se pueden optar por diferentes métodos.
- **Weight on prior:** Es el valor que le asignamos al parámetro *beta* en la ecuación del cálculo del **contenido de información**. Recuerden que la relación entre *alfa* y *beta* es determinante para este cálculo.
- **Information content units:** Generalmente se expresa en *bits*, pero en algunos casos se opta por *half-bits*.

- **Output format:** El tipo de archivo de imagen adonde se guardará el logo.

También tenemos la opción de realizar cambios avanzados, como modificar las frecuencias de *background* o la matriz de *scoring*, limitar la región del alineamiento que queremos graficar, etc. y opciones gráficas, como el tamaño de la imagen y los colores con los que se representa cada aminoácido.

Por convención los colores que se utilizan son:

- **Rojo:** Aminoácidos ácidos [DE]
- **Azul:** Aminoácidos básicos [HKR]
- **Negro:** Aminoácidos hidrofóbicos [ACFILMPVW]
- **Verde:** Aminoácidos polares y glicina [GNQSTY]

Paso 1: Generar el logo con Seq2Logo

1. Ingresa a la página de Seq2Logo: <https://services.healthtech.dtu.dk/service.php?Seq2Logo-2.0>
2. En el campo de texto, pega las 5 secuencias

```
VFAAA
VHYWW
VLQPK
LREWQ
LPYIH
```

3. En las opciones de configuración:
 - **Logo type:** Selecciona *Shannon*.
 - **Clustering method:** Selecciona *None* (para que todas las secuencias pesen igual).
 - **Weight on prior (pseudo counts):** Pon **0**.
 - Deja las demás opciones por defecto.
4. Haz clic en **Generate Logo**.
5. Guarda el logo completo.

Pregunta:

Observa el logo resultante. ¿Cuáles son las posiciones con mayor contenido de información (mayor altura de la columna)? ¿Qué aminoácidos predominan en esas posiciones?

Pregunta:

¿Qué posiciones tienen baja conservación (columnas con poca altura)? ¿Qué aminoácidos aparecen y por qué crees que son variables?

¿Cómo se generan estos logos?

Para entender por qué los logos de los Paso 1 (prior=0) y 2 (prior=200) se ven tan diferentes, tenemos que entender que hace Seq2Logo. La herramienta **traduce las secuencias en una PSSM y luego dibuja las letras en función de los números de esa matriz**.

Te explico el proceso paso a paso y cómo el parámetro **weight on prior** modifica radicalmente el resultado.

Conteo de frecuencias observadas

El programa comienza contando, para cada una de las 5 posiciones, cuántas veces aparece cada aminoácido en tus 5 secuencias.

Por ejemplo, en la **Posición 4** de tus secuencias:

```
Sec1: V F A A A → Pos4 = A
Sec2: V H Y W W → Pos4 = W
Sec3: V L Q P K → Pos4 = P
Sec4: L R E W Q → Pos4 = W
Sec5: L P Y I H → Pos4 = I
```

Conteo observado (sin pseudocuentas):

- W aparece 2 veces → frecuencia = $2/5 = 0.40$

- A, P, I aparecen 1 vez cada uno → frecuencia = 0.20
- El resto de los 16 aminoácidos (incluyendo Y, F, H, etc.) → frecuencia = 0

Paso 2: Asignar Weight on prior

1. Repite exactamente los mismos pasos, pero esta vez cambia el valor de **Weight on prior** a 200.
2. Genera el nuevo logo y toma otra captura de pantalla.

"Weight on prior" (β)

Aquí está la clave de todo. Seq2Logo no se queda solo con los conteos observados, sino que los **mezcla** con un "conocimiento previo" (prior) basado en la matriz de sustitución BLOSUM62. Esta matriz le dice al programa: *"Si ves una W (Triptófano), es muy probable que también puedas encontrar F o Y en su lugar, porque son aminoácidos similares"*.

La fórmula interna que usa el programa es esencialmente:

$$\text{Frecuencia final} = \frac{\alpha \times (\text{Frecuencia observada}) + \beta \times (\text{Prior BLOSUM62})}{\alpha + \beta}$$

- α (alpha): Es el peso que le damos a los datos observados (fijo, suele ser 1).
- β (beta): Es el "Weight on prior" que tú ajustaste (0, 200, etc.).

Una vez que Seq2Logo tiene la tabla de frecuencias, hace dos cosas para dibujar:


1. **Calcula el Score (Log-odds) para cada aminoácido:** $S = \log_2(\text{frecuencia final} / \text{frecuencia de fondo})$. Esto da valores positivos (favorables) y negativos (desfavorables).
2. **Calcula la altura total de la columna (bits):** Suma todas las contribuciones positivas. La fórmula es $\text{Bits} = \sum (\text{frecuencia} \times S)$. Esto mide cuánta información hay en esa posición.
3. **Dibuja las letras:** La altura de cada letra es proporcional a su contribución al total de bits. Las letras con scores negativos (penalizadas) no se dibujan.

Ejercicio 2: Búsqueda de homólogos distantes con PSI-BLAST

¿Qué es PSI-BLAST?

PSI-BLAST (siglas en inglés de *Position-Specific Iterated BLAST*) es una poderosa herramienta bioinformática diseñada para la búsqueda de homologías proteicas. Se trata de una evolución del conocido programa BLASTp que, en lugar de realizar una única comparación de la secuencia de consulta contra una base de datos, ejecuta un proceso de **búsqueda iterativa**.

Su principal objetivo es **detectar relaciones evolutivas distantes entre proteínas** que el BLAST estándar no puede encontrar. Muchas proteínas funcionalmente importantes han divergido tanto a nivel de secuencia que su similitud cae por debajo del "**umbral de penumbra**" (*twilight zone*, aproximadamente 25-30% de identidad), donde la homología ya no puede inferirse de manera fiable mediante comparaciones directas de secuencias.



¿Cómo funciona?

El proceso de PSI-BLAST se puede resumir en los siguientes pasos iterativos:

1. Primera iteración (BLASTp estándar):

La herramienta inicia tomando una **única secuencia proteica** (la consulta) y la compara con una base de datos de proteínas utilizando el programa BLAST con gaps. Esta primera ronda es idéntica a una búsqueda BLASTp normal.

2. Construcción del perfil (PSSM):

A partir de los alineamientos locales significativos encontrados en el paso anterior, el programa construye un **alineamiento múltiple**. De este alineamiento, calcula una **matriz de puntuación específica de posición (PSSM)**, por sus siglas en inglés) o perfil.

Esta matriz no es una simple secuencia, sino un patrón que captura la **información de conservación** en cada posición del alineamiento:

- A las posiciones altamente conservadas se les asignan puntuaciones altas.
- A las posiciones poco conservadas se les asignan puntuaciones cercanas a cero.

3. Búsqueda con el perfil:

La PSSM recién creada se utiliza como la nueva "consulta" para realizar una nueva búsqueda en la base de datos. Esta búsqueda es mucho más sensible porque busca el patrón de conservación, no solo la secuencia original.

4. Iteración y refinamiento:

Las nuevas secuencias significativas encontradas en esta segunda ronda se añaden al alineamiento múltiple, y a partir de él se **refina la PSSM** para la siguiente ronda de búsqueda.

5. Repetición hasta la convergencia:


Este proceso de "construir perfil → buscar → refinar perfil" se repite de forma iterativa (de ahí su nombre) un número determinado de veces o hasta que **no se detecten nuevas secuencias significativas**, un estado conocido como **convergencia**.

Paso 1: Realizar una búsqueda BLAST

1. Ve a la página de BLAST del NCBI: <https://blast.ncbi.nlm.nih.gov/>
2. Selecciona **Protein BLAST**.
3. En el campo de entrada, ingresá la siguiente secuencia:

```
>QUERY1
MKDSDLSTLLSIIRLTELKESKRNALLSLIFQLSVAYFIALVIVSRFVRYVNYITYNNLV
EFIIVLSLIMLIIVTDIFIKKYISKFSNILLETLNLKINSDDNFRREINASKNHNDKNK
LYDLINKTFEKDNIEIKQLGLFISSVINNFAYIILLSIGFILLNEVYSNLFSSRYTTIS
IFTLIVSYMLFIRNKIISSEEEQIEYEKVATSYISSLINRILNTKFTENTTTIGQDKQL
YDSFKTPKIQYGAKVPVKLEEIKEVAKNIEHIPSKAYFVLLAESGLRPGELLNVSINID
LKARIIWINKETQTKRAYSFFSRKTAEFLEKVYLPAREEFIRANEKNIAKLAAANENQE
IDLEKWAKLFPYKDDVLRKKIYEAMDRLGKRFELALRRHFATYMLKKVPPLAINIL
QGRVGPNEFRILKENYTVFTIEDLRKLYDEAGLVVLE
```

4. En la sección **Program Selection**, elige **BLAST**.
5. En el campo de base de datos seleccione pdb que es la base que contiene estructuras.



BLAST® » blastp suite

Standard Protein BLAST

blastn **blastp** blastx tblastn tblastx

BLASTp programs search protein databases using a protein query. [more...](#)

Enter Query Sequence

Enter accession number(s), gi(s), or FASTA sequence(s) [?](#) [Clear](#)

>QUERY1
MKDSDLSTLLSIIRLTELKESKRNALLSLIFQLSVAYFIALVIVSRFVRYVNYITYNNLV
EFIIVLSLIMLIIVTDIFIKKYISKFSNILLETLNLKINSDDNFRREINASKNHNDKNK
LYDLINKTFEKDNIEIKQLGLFISSVINNFAYIILLSIGFILLNEVYSNLFSSRYTTIS
IFTLIVSYMLFIRNKIISSEEEQIEYEKVATSYISSLINRILNTKFTENTTTIGQDKQL
YDSFKTPKIQYGAKVPVKLEEIKEVAKNIEHIPSKAYFVLLAESGLRPGELLNVSINID
LKARIIWINKETQTKRAYSFFSRKTAEFLEKVYLPAREEFIRANEKNIAKLAAANENQE
IDLEKWAKLFPYKDDVLRKKIYEAMDRLGKRFELALRRHFATYMLKKVPPLAINIL
QGRVGPNEFRILKENYTVFTIEDLRKLYDEAGLVVLE

Query subrange [?](#)

From

To

Or, upload file [?](#)

[Browse...](#) No file selected.

Job Title [?](#)

QUERY1

Enter a descriptive title for your BLAST search [?](#)

☐ Align two or more sequences [?](#)

Choose Search Set

Database [?](#)

Protein Data Bank proteins(pdb)

Organism [?](#)

Optional

Enter organism name or id--completions will be suggested [?](#) ☐ exclude [Add organism](#)

Enter organism common name, binomial, or tax id. Only 20 top taxa will be shown. [?](#)

☐ Models (XM/XP) ☐ Non-redundant RefSeq proteins (WP) ☐ Uncultured/environmental sample sequences

Pregunta:

¿Cuántos *hits* con E-value < 0.05 encuentran?

Paso 2: Usando PSI-BLAST

1. Abrí una nueva ventana de BLAST del NCBI: <https://blast.ncbi.nlm.nih.gov/>
2. Selecciona **Protein BLAST**.
3. En el campo de entrada, ingresá la siguiente secuencia:

```
>QUERY1
MKDSDLSTLLSIIRLTELKESKRNALLSLIFQLSVAYFIALVIVSRFVRYVNYITYNNLV
EFIIVLSLIMLIIVTDIFIKKYISKFSNILLETLNLKINSNNFRREIINASKNHNDKNK
LYDLINKTFEKDNIEIKQLGLFIISSVINNFAYIILLSIGFILLNEVYSNLFSSRYTTIS
IFTLIVSYMLFIRNKIISSEEEQIEYEKVATSYISSLINRILNTKFTENTTTIGQDKQL
YDSFKTPKIYQYAKVPVKLEEIKEVAKNIEHIPSKAYFVLLAESGLRPGELNVSIEDID
LKARIWINKETQTKRAYFSFFSRKTAEFLEKVYLPAREEFIRANEKNIAKLAAANENQE
IDLEKWAKLFPYKDDVLRRIYEAMDRLGKRFELALRRHFATYMLKKVPPLAINIL
QGRVGPNEFRILKENYTVFTIEDLRKLYDEAGLVVLE
```

4. En la sección **Program Selection**, elige **PSI-BLAST**.


Preguntas:

Teniendo en cuenta que el primer *hit* es nuestro *query* y por lo tanto vamos a ignorarlo:

1. Ahora, ¿Cuántos *hits* significativos encuentran (E-value < 0.005)?
2. ¿Qué significa la variable **Query Cover**? Una manera visual para entender el *query coverage* es mirar el **Graphic Summary**. Dentro de la pestaña **Descriptions**, coloquen la pestaña **Show** en 100. Luego cliquen en la pestaña **Graphic Summary**. ¿Cuál es la cobertura de los *hits* obtenidos?

Paso 3: Construyendo la PSSM

Si se fijan debajo de los *hits* significativos van a tener la opción de seguir iterando PSI-BLAST:



The screenshot shows the NCBI PSI-BLAST interface. At the top, there's a search bar with the query 'tyrosine-type recombinase/integrase [Metallosphaera cuprina]' and a 'Run' button. Below the search bar, there's a section 'Run PSI-BLAST Iteration 2 with max number of sequences' with a dropdown menu set to '500' and a 'Run' button. Below that, there's a section 'Sequences with E-value WORSE than threshold' with a 'select all' button and '354 sequences selected'. On the right side, there's a 'PSI-BLAST iteration 1' button.

Allí pueden especificar cuantas secuencias queremos utilizar para refinar nuestras PSSM (*Position-Specific Scoring Matrix*). Conservando el valor por defecto corramos la siguiente iteración.

1. Poner "RUN" para ejecutar una segunda iteración.

Preguntas:

1. ¿Cuántos *hits* significativos pueden encontrar ahora (E-value < 0.005)?
2. ¿Cómo se modificó el coverage de estos *hits*? Vuelvan a mirar el **Graphic Summary**, colocando previamente en **Descriptions** la pestaña **Show** en 250.
3. ¿Por qué creen que PSI-BLAST puede identificar ahora más *hits* significativos y que es lo que está afectando el *query coverage*?
4. ¿Qué significan que los *hits* estén resaltados en amarillo, y qué significa que estén en blanco con un tick verde?

Paso 4: Guardando y reutilizando la PSSM

Si no funcionó psi-blast, pueden descargar la matriz desde este [link](#)

Ahora podemos utilizar la PSSM que está ajustada con los resultados obtenidos de PSI-BLAST para realizar búsquedas más significativas en otras bases de datos. Para obtener la PSSM descarguenla arriba donde dice "Download All"

Volvé una vez más a la página para realizar la búsqueda. Sin ingresar ninguna secuencia *query* seleccionemos otra vez la base de datos de estructuras Protein Data Bank (pdb) y como algoritmo PSI-BLAST. Por último, justo debajo del botón de BLAST, abrí el menú de *Algorithm parameters* y carga nuestra PSSM (justo al final). Ahora sí corrí la búsqueda.

Preguntas:

1. ¿Pueden encontrar hits significativos de PDB ahora?
2. ¿Qué función pueden identificar en los primeros hits?

Ejercicio 3: Construcción y uso de un perfil HMM con HMMER

Perfiles HMM (Profile Hidden Markov Models)

Un perfil HMM es un modelo probabilístico que extiende el concepto de PSSM al incluir estados para inserciones y deleciones. Está compuesto por:

- **Estados match ($M_1 \dots M_l$):** emiten un aminoácido según una distribución propia de cada posición (similar a una PSSM).
- **Estados insertion ($I_0 \dots I_l$):** emiten aminoácidos adicionales que no se corresponden con posiciones del alineamiento.
- **Estados deletion ($D_1 \dots D_l$):** estados silenciosos (no emiten) que permiten saltar una posición del alineamiento.

Las transiciones entre estos estados tienen probabilidades que se estiman a partir de las frecuencias observadas de gaps en el alineamiento múltiple. La principal ventaja del HMM es que modela probabilísticamente la longitud variable de las secuencias, penalizando de forma natural las inserciones y deleciones.

HMMER

El paquete **HMMER** (<http://hmmerr.org/>) proporciona herramientas para construir perfiles HMM a partir de alineamientos (`hmmbuild`), calibrarlos (`hmmcalibrate`), buscar en bases de datos (`hmmsearch`) y alinear secuencias contra un perfil (`hmmalign`). Es ampliamente utilizado para la clasificación de familias de proteínas (Pfam) y la búsqueda de homólogos distantes.

En esta práctica vamos a construir un perfil HMM (Modelo Oculto de Markov) a partir de un alineamiento múltiple de la familia de las globinas. Los perfiles HMM son herramientas muy potentes para detectar homólogos lejanos, ya que modelan las posiciones conservadas y las inserciones/deleciones típicas de una familia proteica.

Para ello, usaremos el paquete HMMER. Primero, a partir de un alineamiento en formato MSF, construiremos el perfil con `hmmbuild`. Luego, utilizaremos ese perfil para buscar secuencias similares en una base de datos pequeña (que contiene una globina de *Artemia franciscana*) con `hmmsearch`. Finalmente, interpretaremos los resultados estadísticos para evaluar la calidad de la búsqueda y la sensibilidad del perfil.

Paso 1: Preparar el alineamiento y la base de datos

1. Generá el directorio de trabajo y la estructura de carpetas necesaria para este tutorial
2. Descargá el archivo `globins50.msf`

```
wget "https://raw.githubusercontent.com/mercedesgarnham/Tutoriales/refs/heads/main/TP5/data/globins50.msf"
```

- `globins50.msf` : alineamiento múltiple de 50 globinas. Está en formato MSF (Multiple Sequence Format), un formato de texto plano con cabecera y bloques de secuencias alineadas. Vamos a usar este archivo para construir el HMM

3. Descargá el archivo `Artemia.fa`

```
wget "https://raw.githubusercontent.com/mercedesgarnham/Tutoriales/refs/heads/main/TP5/data/Artemia.fa"
```

- `Artemia.fa` : secuencia de una globina de *Artemia franciscana* en formato FASTA. Este formato es el más estándar: una línea de cabecera que empieza con ">" seguida del identificador, y luego la secuencia en líneas continuas.

Paso 2: Construir el perfil HMM

Para crear el profile utilizamos la función `hmm2build` de la siguiente manera:

```
hmm2build globin.hmm globins50.msfa
```

Esto crea el archivo `globin.hmm` con el perfil.

`hmm2build` recibe como argumentos el archivo en el cual va a guardar el perfil (`globin.hmm`) y el archivo con el cual crearlo (`globins50.msfa`). Si bien el contenido del archivo donde se guardó el perfil es legible, su contenido no debería tener sentido para ustedes (más allá del encabezado con información sobre las opciones que se utilizaron para crearlo) porque únicamente almacena los pesos de las transiciones de estado del HMM.

Paso 3: Calibrar el perfil

Este paso no es imprescindible pero sí aconsejable. La calibración del perfil le otorga mayor sensibilidad en la búsqueda ya que modifica la estimación del E-value de los hits encontrados. Si recuerdan, la búsqueda contra bases de datos nos devuelve junto con cada alineamiento un score y un E-value, este último nos da una idea sobre la cantidad de hits que esperamos encontrar con ese score en una base de datos construida con secuencias aleatorias y se calcula según la longitud de la secuencia query y subject, el tamaño de la base de datos y la matriz de scoring.

En el caso de HMMer, la estimación del E-value es analítica y resulta muy conservativa, por lo que se dejan de lado posibles hits (como homólogos lejanos). Utilizando `hmm2calibrate` podemos calibrar el cálculo de E-values de manera empírica incrementando de manera significativa la sensibilidad de la búsqueda.

```
hmm2calibrate globin.hmm
```

`hmm2calibrate` lee un archivo con un modelo HMM como `globin.hmm` y puntúa un número grande de secuencias sintetizadas al azar (por default 5000 secuencias) con este modelo. Luego ajusta una EVD (Extreme Value Distribution) al histograma de los puntajes obtenidos y guarda nuevamente el modelo HMM con estos nuevos parámetros.

Como para realizar este cálculo se sintetizan secuencias al azar, estableceremos una semilla (o seed) para poder reproducir nuestros resultados. Entonces el comando se modifica de la siguiente forma,

```
hmm2calibrate --seed 1 globin.hmm
```

Paso 4: Buscar el perfil contra la base de datos

El comando para utilizar nuestro flamante profile en una búsqueda es `hmm2search`. En este caso lo vamos a utilizar contra el archivo `Artemia.fa` que contiene una única secuencia de globina en búsqueda de dominios pertenecientes a nuestra familia de interés.

```
hmm2search globin.hmm Artemia.fa
```

Paso 5: Examinar los resultados

La salida de este comando es más larga que las anteriores, consta de un encabezado con la información sobre el programa y los parámetros que utilizamos en la búsqueda:

```
hmmsearch - search a sequence database with a profile HMM
HMMER 2.3.2 (Oct 2003)
Copyright (C) 1992-2003 HHMI/Washington University School of Medicine
Freely distributed under the GNU General Public License (GPL)
-----
HMM file:                globin.hmm [globins50]
Sequence database:       Artemia.fa
per-sequence score cutoff: [none]
per-domain score cutoff:  [none]
per-sequence Eval cutoff:  <= 10
per-domain Eval cutoff:   [none]
-----

Query HMM:  globins50
Accession:  [none]
```

```
Description: [none]
[HMM has been calibrated; E-values are empirical estimates]
```

Una lista parecida a la que da BLAST con los *hits* más importantes ordenados por su E-value:

```
Scores for complete sequences (score includes all domains):
Sequence Description          Score    E-value    N
-----
S13421    S13421 GLOBIN - BRINE SHRIMP    347.5    2.4e-105    8
```

Noten que después del E-value hay un campo que no se encontraba en los otros algoritmos de búsqueda denominado "N". Este valor representa la cantidad de dominios de nuestro *profile* que fueron encontrados en el hit.

Luego encontramos información sobre los dominios de nuestro *profile* individualmente.

```
Parsed for domains:
Sequence Domain  seq-f seq-t    hmm-f hmm-t    score E-value
-----
S13421    6/8    928  1075  ..    1   162  []    66.8  7.9e-21
S13421    2/8    149   288  ..    1   162  []    60.3  7.1e-19
S13421    3/8    303   450  ..    1   162  []    59.4  1.3e-18
S13421    8/8   1238  1390  ..    1   162  []    43.4  8.3e-14
S13421    5/8    771   918  ..    1   162  []    34.8  3.8e-12
S13421    7/8   1085  1234  ..    1   162  []    33.0  5.3e-12
S13421    4/8    454   607  ..    1   162  []    27.1  1.6e-11
S13421    1/8     1   139  [.    1   162  []    22.8  3.5e-11
```

Los campos son:

- el nombre del hit
- el dominio que se alineó (por ej. 2/4 significa que es el dominio Nro 2 de 4 que hay en total en nuestro perfil)
- **seq-f** y **seq-t** son las posiciones del hit donde comienza y termina el alineamiento con ese dominio y el campo siguiente a estos valores (sin nombre) es una codificación de qué parte de la secuencia fue alineada.
 - los corchetes significan extremos y los puntos posiciones en el medio, por lo que:
 - `".."` significa que el alineamiento comenzó y terminó en una posición que no es terminal de la secuencia hit
 - `"["` significa que el alineamiento empieza al comienzo de la secuencia y termina en alguna posición en medio
 - al revés, `"]"` empieza en una posición intermedia y termina en el fin de la secuencia
 - por último `"` es que el dominio abarca toda la secuencia.
- Los tres siguientes campos son análogos pero refiriéndose a la secuencia del dominio en nuestro perfil HMM.
- Luego se reportan el score y el E-value.

La sección siguiente contiene los alineamientos de los dominios que fueron hit en la lista anterior en un formato similar al de BLAST, teniendo como primera secuencia el consenso del *profile* (noten que hay aminoácidos en mayúsculas, estos se encuentran altamente conservados en el *profile*).

Al igual que BLAST en medio de ambas secuencias se escriben los aminoácidos que coinciden o "matchean" y signos más (+) en donde hay matches con puntaje positivo en la matriz de sustitución.

```
Alignments of top-scoring domains:
S13421: domain 6 of 8, from 928 to 1075: score 66.8, E = 7.9e-21
      *->vilealvnssShLSaeekalVkslWYgKVeGnaeeiGaeaLgRlFvv
          +          LSa e a V k++W  V+ ++ ++G  ++  lF +
S13421    928    G-----LSAREVAVVKQTW-NLVKPDLMGVGMRIKSLFEA 962

          YPWtQryFphFgdLsslDavkgsPKvKaHGkKVltaLgdavkhLDdtgnl
          +P  q+ Fp+F+d+ +ld +++ p v +H  V t l++ ++ LD  nl
S13421    963  FPAVQAVFPKFSKV-PLDKLEDTPAVGKHSISVTTKLDELITLDEPANL 1011
```

```

          kgalakLSe lHadklrVDPeNFk lLghv lvvvLaehfgkdftPevqAAwd
          +   +L+e H   lrV+   Fk +g+vlv L   +g f+   +   +w
S13421  1012 ALLARQLGEDH-IVLRVNKPMFKSFGKVLVRLLENDLGQRFSFASRSWH 1060

          KflagvanaLahKYr<-*
          K+++++   +++
S13421  1061 KAYDIVEYIEEGLQ      1075

```

Llegando al final encontramos un histograma, similar al que nos mostraba FASTA. En este caso como nuestra "base de datos" tiene una sola secuencia no es informativo en absoluto.

```

Histogram of all scores:
score    obs    exp (one = represents 1 sequences)
-----
347      1      0|=

```

Y por último algunos detalles estadísticos que corresponden al ajuste de la EVD, en los cuales no vamos a focalizar.

```

% Statistical details of theoretical EVD fit:
      mu = -107.8777
      lambda = 0.1843
chi-sq statistic = 0.0000
P(chi-square) = 0

Total sequences searched: 1

Whole sequence top hits:
tophits_s report:
  Total hits: 1
  Satisfying E cutoff: 1
  Total memory: 20K

Domain top hits:
tophits_s report:
  Total hits: 8
  Satisfying E cutoff: 8
  Total memory: 25K

```

Pregunta:

¿Cuántos hits significativos (E-value < 0.05) encontré en mi búsqueda? ¿Cuáles es el mejor hit y qué score tiene?

HMMer puede leer los formatos de la mayoría de las bases de datos conocidas. A diferencia de BLAST no es necesario indexar la base de datos. HMMer puede realizar la búsqueda directamente sobre el multifasta sin necesidad de más procesamiento.

Ejercicio 4: Identificación de dominios con bases de datos

InterPro es un recurso de análisis de secuencias de proteínas, mantenido por el EMBL-EBI, que clasifica las proteínas en familias y predice la presencia de dominios y sitios funcionales importantes.

Para lograrlo, InterPro **integra** modelos predictivos (llamados *firmas* o *signatures*) provenientes de **13 bases de datos especializadas**. Cada una de estas bases tiene sus propias fortalezas: algunas se especializan en dominios conservados, otras en motivos cortos, familias completas o superfamilias estructurales.

InterPro combina todas estas firmas en un **único recurso** no redundante. Esto significa que si un dominio está descrito por varias bases con distinto nivel de detalle, InterPro las agrupa en una sola entrada, añadiendo además **descripciones textuales**, referencias bibliográficas y términos de **Gene Ontology (GO)** curadas manualmente.

Base de datos	Tipo de modelo	¿Qué busca?	Fortalezas	Debilidades
Pfam	HMM (perfil)	Dominios y familias de proteínas	Muy curada manualmente, cobertura amplia, es la más usada	Puede perder dominios muy divergentes
TIGRFAMs	HMM (perfil)	Familias de proteínas (especialmente bacterianas)	Muy específica para anotación genómica, modelos jerárquicos	Enfocada en procariotas, menos cobertura en eucariotas
SMART	HMM (perfil)	Dominios de señalización y de membrana	Excelente para proteínas de señalización, factores de transcripción, dominios extracelulares	Menos general que Pfam, enfocada en ciertos tipos de dominios
PANTHER	HMM (perfil)	Familias y subfamilias, con clasificación jerárquica	Clasifica en árboles filogenéticos, asocia GO automáticamente	Modelos menos precisos para dominios muy conservados
HAMAP	HMM (perfil)	Proteínas de bacterias y arqueas	Curada manualmente, muy específica para anotación automática de genomas	Solo microorganismos
PROSITE	Patrones (expresiones regulares) y perfiles	Motivos cortos y dominios	Detecta motivos funcionales muy específicos (sitios activos, unión a metales)	Baja sensibilidad para dominios completos, muchos falsos negativos
PRINTS	Huellas dactilares (fingerprints)	Motivos conservados de varios fragmentos	Robusta porque usa múltiples motivos no solapados	Menos usada actualmente, cobertura limitada
ProDom	Agrupamiento por similitud de secuencia	Dominios proteicos	Buena cobertura, actualizada automáticamente	Menos curada, puede tener dominios no funcionales
SUPERFAMILY	HMM (perfil)	Clasificación estructural por superfamilias de SCOP	Relaciona secuencia con estructura 3D (pliegues)	No da información funcional directa
CDD (Conserved Domain Database)	HMM y perfiles de posición específica	Dominios conservados (NCBI)	Integrada con BLAST, útil para anotación rápida	Menos curada que Pfam, más automática
PIRSF	Clasificación jerárquica manual	Familias de proteínas completas (no solo dominios)	Clasifica proteínas completas, no dominios aislados	Menos utilizada en búsquedas por secuencia corta
CATH-Gene3D	HMM (perfil)	Clasificación estructural por CATH (pliegues)	Relaciona dominios con estructuras 3D	No da información funcional, solo estructural
MobiDB	Anotación de desorden	Regiones intrínsecamente desordenadas	Útil para identificar regiones flexibles sin estructura	No clasifica dominios, solo desorden

El resultado es una herramienta muy potente: al enviar una secuencia, InterPro te dice **a qué familia pertenece, qué dominios tiene y qué función probable cumple**, todo en un solo lugar.

¿Cómo funciona la búsqueda por secuencia?

InterPro ofrece dos formas principales de buscar:

1. **Búsqueda por texto:** para explorar entradas ya curadas (por nombre de dominio, ID de proteína, organismo, etc.).
2. **Búsqueda por secuencia:** la que usaremos aquí. Consiste en enviar una secuencia de aminoácidos (en formato FASTA o texto plano) para que el motor **InterProScan** la analice.

InterProScan es el software que ejecuta el análisis real. Toma tu secuencia y la compara contra **todas las firmas** de las 13 bases de datos integradas en InterPro. Luego, te devuelve un listado de todos los dominios, familias y sitios que encontró, indicando en qué posición de la secuencia aparecen, con qué puntuación y de qué base de datos proviene cada predicción.

En este ejercicio, utilizaremos la base de datos de perfiles **Pfam** (accesible a través de **InterPro**) para identificar dominios en una proteína de interés.

Paso 1: Buscar en InterPro

1. Ve a <https://www.ebi.ac.uk/interpro/>

2. Subí el archivo `Artemia.fa`.
3. Hacé clic en **"Search"** para iniciar el análisis.

Preguntas:

1. ¿Cuál es la longitud de la proteína y la familia principal a la que pertenece según InterPro?
2. ¿Cuántos dominios tipo globina se predicen? ¿En qué posiciones de la secuencia aparecen?
3. ¿Qué bases de datos (Pfam, SMART, PROSITE, etc.) coinciden en la predicción de dominios? ¿Hay alguna que prediga algo diferente? ¿Qué nos dice eso sobre la robustez de la anotación?

Interpretación de los resultados de InterPro para *Artemia franciscana*

Vamos a desglosar qué significa cada sección para que puedas entender bien qué nos dice esta herramienta sobre nuestra proteína.

Resumen general

La secuencia analizada pertenece a una proteína de *Artemia franciscana* identificada como **Globin - brine shrimp**. Lo primero que llama la atención es su **longitud: 1405 aminoácidos**. Una globina típica (como la mioglobina o la hemoglobina de vertebrados) tiene alrededor de 150 aminoácidos. Este tamaño tan grande nos indica que no es una globina simple, sino una **proteína multidominio**, probablemente una **eritrocruorina**.

Las eritrocruorinas son hemoglobinas gigantes presentes en algunos invertebrados (como lombrices de tierra y artemias). Están formadas por múltiples dominios tipo globina unidos en una sola cadena polipeptídica, y suelen funcionar como transportadores de oxígeno en el medio extracelular.

Identificador y familia principal

- **Sequence ID:** `S13421 S13421 GLOBIN - BRINE SHRIMP` → Es el código de la secuencia en la base de datos y la descripción.
- **Protein family membership:** `Erythrocrurin (IPR002336)` → InterPro asigna esta proteína a la familia de las **eritrocruorinas**. Este es un dominio específico de estas hemoglobinas gigantes de invertebrados.

Representación gráfica de los dominios

La barra horizontal representa la secuencia completa de 1405 aa. Los rectángulos de colores indican las regiones donde distintas bases de datos (Pfam, SMART, CDD, etc.) predicen dominios.

Observá que **hay múltiples bloques de color a lo largo de toda la secuencia**. Cada bloque corresponde a un dominio tipo globina. En esta proteína se detectan al menos **5 o 6 dominios globina** repetidos, lo cual es típico de las eritrocruorinas. Esto explica por qué la proteína es tan larga: está compuesta por varios módulos globina en tándem.

Familias y dominios identificados

En el panel izquierdo ("Families") y derecho ("Domains") se listan las firmas que coincidieron:

- **Globin-like, Globins, Globin** (varias veces) → Todos estos son nombres de dominios o familias relacionados con globinas.
- **Mb-like** (mioglobina-like) → Indica similitud con el pliegue de la mioglobina, que es el pliegue canónico de las globinas.
- **PROFILE: GLOBIN, PFAM: Globin, CATHGEN3D: Globins, SSF: Globin-like** → Estos son identificadores de diferentes bases de datos que coinciden en predecir un dominio globina. Que varias fuentes coincidan refuerza la confianza en la predicción.
- **Globin-like_sf** → "Superfamilia globina-like", una categoría más amplia.

En resumen, **todas las bases de datos integradas en InterPro coinciden en que esta proteína contiene múltiples dominios de la familia de las globinas**.

Comparación con tu resultado de HMMER

Recordá que antes usaste `hmmsearch` con un perfil construido a partir de 50 globinas alineadas. Ese perfil detectó la secuencia de *Artemia* porque contiene al menos un dominio globina, pero el perfil único no puede decirte cuántos dominios tiene ni darte información sobre la función completa de la proteína.

InterPro, en cambio, al integrar múltiples bases de datos, te muestra:

- Que no es una globina simple, sino una **eritrocruorina** con múltiples dominios.
- La organización modular de la proteína (cuántos dominios y en qué posiciones).
- Información funcional (GO) y estructural (familias, superfamilias).

Esto demuestra la ventaja de usar herramientas integradas cuando queremos una caracterización completa de una proteína desconocida.

Cierre del Tutorial

Completa la siguiente tabla para resumir lo visto:

Tema	Herramienta(s) utilizada(s)	Tipo de datos	Análisis del resultado
Sequence Logos y PSSM			
PSI-BLAST			
Perfiles HMM			
Identificación de dominios			

Verificación de objetivos

- Construir e interpretar **Sequence Logos** a partir de alineamientos de secuencias. (Sí / No)
- Comprender el concepto de **PSSM** y su utilidad para representar la conservación en un alineamiento múltiple. (Sí / No)
- Familiarizarse con **PSI-BLAST** y su capacidad para detectar homólogos distantes mediante búsquedas iterativas. (Sí / No)
- Comprender y construir un perfil HMM desde un alineamiento múltiple y realizar búsquedas en bases de datos. (Sí / No)
- Utilizar InterPro para la identificación de dominios y familias. (Sí / No)

Bibliografía complementaria

- Eddy SR (1998) Profile hidden Markov models. *Bioinformatics* 14(9):755-763.
- Altschul SF, Madden TL, Schäffer AA, et al. (1997) Gapped BLAST and PSI-BLAST: a new generation of protein database search programs. *Nucleic Acids Res* 25(17):3389-3402.
- Crooks GE, Hon G, Chandonia JM, Brenner SE (2004) WebLogo: a sequence logo generator. *Genome Res* 14:1188-1190.
- HMMER user guide: <http://hmmer.org/>
- Finn RD, Bateman A, Clements J, et al. (2014) Pfam: the protein families database. *Nucleic Acids Res* 42(D1):D222-D230.