

TP 5. Uso de información contenida en alineamientos múltiples (Parte II): PSI-BLAST, PSSMs, Profiles, HMMs, Sequence Logos

Objetivos

1. Comprender el concepto de **PSSM** (Position-Specific Scoring Matrix) y su utilidad para representar la conservación en un alineamiento múltiple.
2. Familiarizarse con **PSI-BLAST** y su capacidad para detectar homólogos distantes mediante búsquedas iterativas.
3. Construir e interpretar **Sequence Logos** a partir de alineamientos de secuencias.
4. Conocer la arquitectura de un **perfil HMM** (estados match, inserción y delección) y su ventaja sobre las PSSM para modelar familias con inserciones/delecciones.
5. Utilizar el paquete **HMMER** para construir un perfil HMM desde un alineamiento múltiple y realizar búsquedas en bases de datos.
6. Comparar los resultados obtenidos con PSI-BLAST y HMMER, y reflexionar sobre sus aplicaciones.

Introducción

De la secuencia consenso al perfil probabilístico

En el TP anterior trabajamos con motivos lineales representados por expresiones regulares. Sin embargo, estos patrones son rígidos y no capturan la variabilidad completa de una familia de proteínas. Para familias con múltiples alineamientos, necesitamos modelos que asignen un peso a cada aminoácido en cada posición y que manejen inserciones y delecciones.

PSSM (Position-Specific Scoring Matrix)

Una PSSM (también llamada perfil o matriz de pesos) es una tabla donde, para cada posición de un alineamiento, se almacena una puntuación (log-odds) para cada uno de los 20 aminoácidos. Se construye a partir de las frecuencias observadas en el alineamiento, corregidas con pseudocuentas y comparadas con frecuencias de fondo. Una PSSM permite puntuar qué tan bien encaja una nueva secuencia en el perfil de la familia. Sin embargo, las PSSM no modelan de forma explícita los gaps (inserciones/delecciones) de longitud variable.

Sequence Logos

Un **Sequence Logo** es una representación gráfica de una PSSM. En cada posición, la altura total de la columna de letras es proporcional al contenido de información (conservación), y la altura de cada letra refleja su frecuencia en esa posición. Los colores suelen agrupar aminoácidos por propiedades químicas. Los logos permiten visualizar de un vistazo las posiciones conservadas y las variables.

PSI-BLAST (Position-Specific Iterated BLAST)

PSI-BLAST es una variante de BLAST que realiza búsquedas iterativas. En la primera ronda, se comporta como un BLASTp normal. Con los resultados significativos, construye una PSSM específica de la consulta. En las rondas siguientes, utiliza esa PSSM para buscar en la base de datos, lo que permite encontrar homólogos más distantes que los que se obtendrían en una única ronda. El proceso se repite hasta que no se encuentren nuevos hits o hasta que el usuario decida detenerlo.

Perfiles HMM (Profile Hidden Markov Models)

Un perfil HMM es un modelo probabilístico que extiende el concepto de PSSM al incluir estados para inserciones y deleciones. Está compuesto por:

- **Estados match ($M_1 \dots M_i$):** emiten un aminoácido según una distribución propia de cada posición (similar a una PSSM).
- **Estados insertion ($I_0 \dots I_i$):** emiten aminoácidos adicionales que no se corresponden con posiciones del alineamiento.
- **Estados deletion ($D_1 \dots D_i$):** estados silenciosos (no emiten) que permiten saltar una posición del alineamiento.

Las transiciones entre estos estados tienen probabilidades que se estiman a partir de las frecuencias observadas de gaps en el alineamiento múltiple. La principal ventaja del HMM es que modela probabilísticamente la longitud variable de las secuencias, penalizando de forma natural las inserciones y deleciones.

HMMER

El paquete **HMMER** (<http://hmmmer.org/>) proporciona herramientas para construir perfiles HMM a partir de alineamientos (`hmmbuild`), calibrarlos (`hmmcalibrate`), buscar en bases de datos (`hmmsearch`) y alinear secuencias contra un perfil (`hmmalign`). Es ampliamente utilizado para la clasificación de familias de proteínas (Pfam) y la búsqueda de homólogos distantes.

Ejercicio 1: Generación e interpretación de un Sequence Logo

En este ejercicio vamos a construir un logo de secuencia a partir de un alineamiento de la familia de las globinas. Utilizaremos **WebLogo** para visualizar la conservación y deducir las posiciones clave de la familia.

Paso 1: Obtener un alineamiento de globinas

1. Descarga el archivo `globins50.msf` desde los materiales del curso (o desde el repositorio de la clase). Si no lo tienes, puedes usar el alineamiento de globinas que se proporciona en la carpeta del TP.
2. Visualiza el alineamiento con `less` o `cat` para confirmar que es un alineamiento múltiple en formato MSF (o Stockholm).

Paso 2: Generar el logo con WebLogo

1. Ve a la página de WebLogo: <https://weblogo.threeplusone.com/create.cgi>
2. Sube el archivo `globins50.msf` o copia y pega el contenido del alineamiento en formato FASTA (puedes convertir el MSF a FASTA con Jalview o manualmente).
3. Configura los parámetros:
 - **Output Format:** PNG
 - **Sequence type:** Protein
 - **Composition:** No adjustment for composition
 - **Error bars:** No
 - **Color scheme:** Chemistry (AA)
 - **Y-axis scale:** 4.5
4. Haz clic en **Create Logo**.

Pregunta 1:

Observa el logo resultante. ¿Cuáles son las posiciones con mayor contenido de información (mayor altura de la columna)? ¿Qué aminoácidos predominan en esas posiciones? ¿Tienen alguna relación con la función de las globinas (por ejemplo, la unión al grupo hemo)?

Pregunta 2:

¿Qué posiciones tienen baja conservación (columnas con poca altura)? ¿Qué aminoácidos aparecen y por qué crees que son variables? ¿Cómo se relaciona esto con la evolución de las globinas?

Paso 3: Comparar con la secuencia consenso

1. A partir del alineamiento, escribe la secuencia consenso (el aminoácido más frecuente en cada columna) para las primeras 20 posiciones del alineamiento.
2. Compara esa secuencia consenso con el logo: ¿coinciden en las posiciones conservadas? ¿El logo te da más información que la secuencia consenso? Explica.

Ejercicio 2: Búsqueda de homólogos distantes con PSI-BLAST

PSI-BLAST es una herramienta del NCBI que permite encontrar homólogos lejanos mediante búsquedas iterativas. En este ejercicio, usaremos como consulta la secuencia de la mioglobina humana (o cualquier globina) y realizaremos varias iteraciones para ver cómo mejora la detección.

Paso 1: Realizar una búsqueda PSI-BLAST

1. Ve a la página de BLAST del NCBI: <https://blast.ncbi.nlm.nih.gov/>
2. Selecciona **Protein BLAST**.
3. En el campo de entrada, pega la secuencia de mioglobina humana (puedes obtenerla de UniProt con ID **P02144**) en formato FASTA.
4. En la sección **Program Selection**, elige **PSI-BLAST (Position-Specific Iterated BLAST)**.
5. Deja los parámetros por defecto (base de datos **nr**, organismo **Homo sapiens** o cualquier otro, o puedes seleccionar **swissprot** para una base más curada). Ejecuta la búsqueda.
6. Una vez que termine la primera ronda, verás un botón **Run PSI-BLAST iteration 2** en la parte superior de los resultados. Haz clic en él y espera a que termine la segunda iteración. Repite el proceso para una tercera iteración.

Pregunta 3:

Compara el número de hits significativos ($E\text{-value} \leq 0.05$) entre la iteración 1, la 2 y la 3. ¿Aumenta el número de secuencias encontradas a medida que avanzas en las iteraciones? ¿Qué te dice esto sobre la sensibilidad de PSI-BLAST?

Paso 2: Identificar la PSSM generada

Durante el proceso, PSI-BLAST construye una PSSM específica para tu consulta. En los resultados, puedes ver la PSSM si seleccionas la opción **Show PSSM** (está en la parte superior de la página de resultados, cerca del botón de iteración). Visualízala.

Pregunta 4:

Observa la PSSM. ¿Qué diferencias notas con respecto a una matriz de sustitución estándar (como BLOSUM62)? ¿Cómo se refleja en los valores de la PSSM la conservación observada en el logo del Ejercicio 1?

Paso 3: Buscar un homólogo lejano conocido

En la tercera iteración, busca si aparecen secuencias de globinas de organismos muy distantes, por ejemplo, de plantas (leghemoglobinas) o de bacterias (hemoglobinas bacterianas). Anota algún identificador (Accession) de una secuencia que solo aparezca en la iteración 3 y no en la 1.

Pregunta 5:

Elige una secuencia que haya aparecido solo en iteraciones tardías. ¿Cuál es su organismo? ¿Cuál es su porcentaje de identidad respecto a tu consulta original? ¿Por qué crees que PSI-BLAST pudo encontrarla en rondas posteriores?

Ejercicio 3: Construcción y uso de un perfil HMM con HMMER

En este ejercicio utilizaremos el paquete HMMER para construir un perfil HMM a partir del alineamiento de globinas (el mismo que usaste para el logo) y luego buscar ese perfil contra una base de datos de secuencias.

Paso 1: Preparar el alineamiento y la base de datos

1. Asegúrate de tener el alineamiento `globins50.msf` (o el que hayas usado) en un directorio de trabajo. Si el archivo está en formato MSF, HMMER acepta MSF, Stockholm y FASTA.
2. Descarga una base de datos pequeña para pruebas, por ejemplo, el archivo `Artemia.fa` que contiene una globina de *Artemia franciscana*, o un subconjunto de Swiss-Prot. En la carpeta del TP hay un archivo `Swissprot_small.fasta` que puedes usar. Si no, puedes descargar solo unas pocas secuencias de globinas de diferentes organismos para tener una base de datos personalizada.

Paso 2: Construir el perfil HMM

Ejecuta el siguiente comando en la terminal (recuerda que debes tener instalado `hmm2` o `hmm3`; en este ejemplo usamos `hmm3` de HMMER3, que es el estándar actual):

```
hmmbuild globin.hmm globins50.msf
```

Esto crea el archivo `globin.hmm` con el perfil.

Paso 3: Calibrar el perfil (opcional pero recomendado)

La calibración mejora la estimación del E-value:

```
hmmcalibrate --seed 1 globin.hmm
```

Paso 4: Buscar el perfil contra la base de datos

Usa `hmmsearch` para buscar el perfil en tu base de datos:

```
hmmsearch globin.hmm Artemia.fa > globin_vs_Artemia.out
```

O si usas un archivo más grande, ajusta el nombre de salida.

Paso 5: Examinar los resultados

Abre el archivo de salida con `less` o `head` para ver las primeras líneas. La salida incluye una tabla con los hits, sus scores y E-values, y luego los alineamientos detallados.

Pregunta 6:

¿Cuántos hits significativos (E-value < 0.05) encontró `hmmsearch` en tu base de datos? ¿Cuál es el mejor hit y qué score

tiene? Compara este resultado con el que obtuviste con PSI-BLAST para la misma secuencia (si usaste una consulta similar). ¿Qué método parece más sensible?

Paso 6: Alinear una secuencia contra el perfil

Usa `hmmalign` para alinear una secuencia nueva (por ejemplo, la de *Artemia*) contra el perfil HMM:

```
hmmalign -o Artemia.ali.sto globin.hmm Artemia.fa
```

Luego visualiza el alineamiento resultante.

Pregunta 7:

Observa el alineamiento producido por `hmmalign`. ¿Se insertan gaps en regiones donde el perfil tiene baja probabilidad de emisión? ¿Cómo maneja las inserciones y deleciones en comparación con un alineamiento por pares tradicional (Needleman-Wunsch)?

Ejercicio 4: Comparación entre PSI-BLAST, PSSM y HMM

En este ejercicio integraremos los conceptos vistos y reflexionaremos sobre las ventajas y limitaciones de cada enfoque.

Paso 1: Construir una PSSM a mano

A partir del alineamiento de globinas, elige las primeras 5 posiciones y calcula las frecuencias de cada aminoácido. Luego, convierte esas frecuencias en log-odds (puedes usar la fórmula: $\log_2(\text{frecuencia} / \text{frecuencia_fondo})$). Usa una frecuencia de fondo uniforme (1/20) o la composición de Swiss-Prot (puedes obtenerla de la tabla del TP4).

Pregunta 8:

¿Qué valores positivos y negativos obtuviste? ¿Qué significa un valor positivo para un aminoácido en una posición? ¿Y un valor negativo?

Paso 2: Reflexionar sobre la diferencia entre PSSM y HMM

Compara la arquitectura de una PSSM (longitud fija, sin estados de gaps) con la de un perfil HMM (estados M, I, D). Piensa en el caso de una familia con inserciones de longitud variable en posiciones específicas.

Pregunta 9:

¿Por qué un HMM es más adecuado que una PSSM para representar una familia de proteínas con gaps? ¿Qué limitación tiene una PSSM simple cuando una secuencia nueva tiene una inserción en una región variable?

Paso 3: Ventajas de PSI-BLAST frente a HMMER

Aunque ambos son métodos de búsqueda basados en perfiles, PSI-BLAST es más rápido y se integra bien con la web, mientras que HMMER es más sensible y flexible (puede modelar gaps). Reflexiona sobre cuándo usarías uno u otro.

Pregunta 10:

Imagina que tienes un alineamiento múltiple de 100 secuencias de una familia de quinasa y quieres encontrar nuevos miembros en el proteoma humano. ¿Usarías PSI-BLAST o HMMER? Justifica tu respuesta en términos de sensibilidad, velocidad y manejo de gaps.

Ejercicio 5 (opcional): Identificación de dominios con bases de datos de HMM

En este ejercicio, utilizaremos la base de datos de perfiles **Pfam** (accesible a través de **InterPro**) para identificar dominios en una proteína de interés.

Paso 1: Buscar en InterPro

1. Ve a <https://www.ebi.ac.uk/interpro/>
2. En el buscador, introduce el accession de la proteína *Sevenless* de *Drosophila melanogaster*: **P13368** (puedes usar cualquier otra proteína con dominios conocidos, como una quinasa o una proteína con dominios de unión a ADN).
3. En la tabla de resultados, expande la sección **Domains** y observa los dominios Pfam que se identifican.

Pregunta 11:

¿Qué dominios Pfam encontró InterPro? ¿En qué posiciones de la proteína se localizan? ¿Qué función tienen esos dominios según la descripción de Pfam?

Paso 2: Usar HMMER contra una base de datos de perfiles personalizada

En el material del TP se proporcionan varios archivos `.sto` con perfiles de dominios (p. ej., RRM, FN3, pkinase). Puedes construir una base de datos de perfiles y buscar contra la secuencia de *Sevenless*, siguiendo los pasos del ejercicio adicional del TP11.

Si tienes los archivos, puedes ejecutar:

```
hmm2build -A myhmms rrm.sto
hmm2build -A myhmms fn3.sto
hmm2build -A myhmms pkinase.sto
hmm2pfam myhmms 7LES_DROME
```

Pregunta 12:

Observa los resultados de ``hmm2pfam``. ¿Coinciden los dominios encontrados con los de InterPro? ¿Hay algún dominio falso positivo (como el RRM que aparece con E-value cercano a 1)? ¿Cómo podrías filtrar esos falsos positivos ajustando el umbral de E-value?

Cierre y reflexión final

En este TP hemos cubierto herramientas y conceptos fundamentales para el análisis de familias de proteínas:

- **PSSM**: representación posición-específica de las frecuencias de aminoácidos.
- **Sequence Logos**: visualización de la conservación y la variabilidad.
- **PSI-BLAST**: búsqueda iterativa que construye una PSSM para encontrar homólogos distantes.
- **HMMER**: construcción y uso de perfiles HMM que modelan explícitamente inserciones y delecciones.

Completa la siguiente tabla resumen:

Tema	Herramienta(s)	Tipo de datos	Ventajas	Limitaciones
PSSM	(completar)	(completar)	(completar)	(completar)
PSI-BLAST	(completar)	(completar)	(completar)	(completar)
Perfil HMM / HMMER	(completar)	(completar)	(completar)	(completar)
Sequence Logos	(completar)	(completar)	(completar)	(completar)

✓ Objetivos alcanzados

- Comprender el concepto de PSSM y su utilidad. (Sí / No) - Utilizar PSI-BLAST para encontrar homólogos distantes. (Sí / No) - Generar e interpretar un Sequence Logo. (Sí / No) - Construir un perfil HMM con HMMER y realizar búsquedas. (Sí / No) - Comparar los enfoques de PSSM, PSI-BLAST y HMM. (Sí / No)

Bibliografía complementaria

- Eddy SR (1998) Profile hidden Markov models. *Bioinformatics* 14(9):755-763.
- Altschul SF, Madden TL, Schäffer AA, et al. (1997) Gapped BLAST and PSI-BLAST: a new generation of protein database search programs. *Nucleic Acids Res* 25(17):3389-3402.
- Crooks GE, Hon G, Chandonia JM, Brenner SE (2004) WebLogo: a sequence logo generator. *Genome Res* 14:1188-1190.
- HMMER user guide: <http://hmmer.org/>
- Finn RD, Bateman A, Clements J, et al. (2014) Pfam: the protein families database. *Nucleic Acids Res* 42(D1):D222-D230.